作品编号：

2025年(第十一届)全国大学生统计建模大赛

参 赛 作 品

参赛学校：铜陵学院

论文题目：基于多算法融合的时序价格模型预测苹果市场价格波动规律——以广州市苹果批发市场价格为例

参赛队员：昝雨欣 王光宇 曹依雯

指导老师：徐良志

基于多算法融合的时序价格模型预测苹果市场价格波动规律——以广州市苹果批发市场价格为例

摘要

粮食乃“国之大者”，近年来，农产品价格波动已成为全球农业经济领域的重要议题。作为农业大国，我国的经济社会的可持续发展与农产品价格稳定与否息息相关。随着大数据、人工智能等技术的快速发展，传统预测模型在数据维度和非线性关系解析上的局限性日益凸显，精准预测对政策调控和产业链管理具有重要意义。因此，为解决上述问题，本文结合大数据技术和多种统计模型对农产品价格进行研究预测，并提出了相关建议和决策。

本研究以广州市苹果批发市场价格为研究对象，构建基于机器学习的多算法融合的时序预测模型，探索大数据与统计技术在农产品价格分析中的创新应用。通过 Python 爬虫获取广州江南果菜批发市场网站上 2019—2025 年的日度价格数据，结合 SPSS 进行缺失值插补、异常值处理等操作，利用皮尔逊相关系数筛选关键特征。在此基础上，对比分析 BP 神经网络、遗传算法 GA 优化 BP 神经网络、粒子群 PSO 优化 BP 神经网络、粒子群 PSO 优化支持向量机 SVM 以及卷积神经网络 CNN 等模型的预测效能。

实证表明，BP 神经网络训练集与测试集性能差异较大，存在一定过拟合风险。GA-BP 模型在测试集上表现最优，其泛化能力显著优于其他模型，且系统性偏差最小。而 PSO 有效改善了 BP 网络初始权值的随机性问题，但其在参数空间探索广度上仍逊于遗传算法。粒子群有效提升了 SVM 对非线性价格波动的适应性，但预测结果显示该模型稳定性稍弱。卷积神经网络展现出超强拟合能力，但在预测阶段存在过拟合问题。通过对比五种模型的预测效果，综合考量，GA-BP 成为实际应用中预测任务的首选模型，是最能预测广州市水果批发市场苹果价格的模型。

总之，本研究旨在通过大数据分析手段，验证了智能算法融合大数据技术在挖掘非线性时序特征、提升预测精度中的有效性，为广州市农产品市场监测与政策制定提供了创新与实用的解决方案，为并相关部门提供了有效的价格行情监测和市场调控预警手段，对于维护社会经济稳定和粮食安全具有重要意义。

关键词：农产品；苹果；大数据；价格预测；神经网络

目录

摘要.....2
一、 引言.....7
（一） 研究背景与意义.....7
（二） 研究现状.....7
（三） 研究思路.....8
二、 机制分析.....10
（一） 问题分析.....10
（二） 模型假设.....10
1. 数据假设.....10
2. 模型假设.....10
三、 数据分析.....11
（一） 数据来源.....11
（二） 指标选取.....12
（三） 描述性统计分析.....12
1. 散点图.....12
2. 正态分布.....13
（四） 数据预处理.....15
1. 缺失值处理.....15
2. 异常值处理.....16
3. 数据标准化.....16
4. 相关性分析.....17
四、 基于融合模型的农产品价格预测算法.....18
（一）BP 神经网络.....18
（二）遗传算法 GA 优化 BP 神经网络.....19
（三）粒子群算法 PSO 优化 BP 神经网络.....20
（四）粒子群算法 PSO 优化支持向量机 SVM.....21
（五）卷积神经网络 CNN.....23
五、 预测结果与分析.....25

（一） 模型预测结果.....25
1. BP 神经网络对苹果价格的预测.....25
2. GA-BP 对苹果价格的预测.....27
3. PSO-BP 对苹果价格的预测.....30
4. PSO-SVM 对苹果价格的预测.....33
5. CNN 对苹果价格的预测.....36
（二） 优化后模型评价及对比分析.....38
1. 预测结果.....38
2. 模型分析.....41
六、 总结与展望.....42
（一） 结论.....42
（二） 建议与展望.....42
参考文献.....44
附录.....47
致谢.....49

表格和插图清单

表目录

表 1　爬取数据存储示例.....11
表 2　SPSS 频率统计.....15
表 3　EM 缺失值插补.....15
表 4　Pearson 相关系数.....17
表 5　BP 模型预测结果.....27
表 6　GA-BP 模型预测结果.....30
表 7　PSO-BP 模型预测结果.....32
表 8　PSO-SVM 模型预测结果.....36
表 9　CNN 模型预测结果.....38
表 10　部分模型预测结果比较.....39

图目录

图 1　研究流程图.....9
图 2　数据可视化结果.....12
图 3　各指标散点图.....13
图 4　价格 P-P 图.....14
图 5　日照时数 P-P 图.....14
图 6　箱线图.....16
图 7　BP 训练集预测结果对比.....25
图 8　训练集预测值 vs 训练集真实值.....26
图 9　测试集预测结果对比.....26
图 10　测试集预测值 vs 测试集真实值.....26
图 11　GA-BP 适应度变化曲线.....28
图 12　GA-BP 训练集预测结果对比.....28
图 13　GA-BP 训练集预测值 vs 训练集真实值.....28
图 14　GA-BP 测试集预测结果对比.....29
图 15　GA-BP 测试集预测值 vs 测试集真实值.....29
图 16　PSO-BP 训练集预测结果对比.....30

图 17　PSO-BP 训练集预测值 vs 训练集真实值 31
图 18　PSO-BP 测试集预测结果对比 31
图 19　PSO-BP 测试集预测值 vs 测试集真实值 32
图 20　粒子群模型迭代误差变化.....33
图 21　PSO-SVM 训练集预测结果对比 34
图 22　PSO-SVM 训练集预测值 vs 训练集真实值.....34
图 23　PSO-SVM 测试集预测结果对比 34
图 24　PSO-SVM 测试训练集预测值 vs 测试集真实值.....35
图 25　PSO-SVM 最佳适应度曲线 35
图 26　CNN 训练集预测结果对比 36
图 27　CNN 训练集预测值 vs 训练集真实值.....37
图 28　CNN 测试集预测结果 37
图 29　CNN 测试训练集预测值 vs 测试集真实值.....38
图 30　不同模型预测结果对比.....40

基于多算法融合的时序价格模型预测苹果市场价格波动规律
——以广州市苹果批发市场价格为例

一、引言

（一）研究背景与意义

“粮头食尾”、“农头工尾”，近年来，农产品价格波动已成为全球农业经济领域的重要议题。作为国民经济的基础产业，农业的稳定直接关系到粮食安全、农民收入和社会经济可持续发展[1]。根据联合国粮农组织（FAO）统计，2020 年全球农产品价格指数波动幅度达 28%，创十年新高；我国农业农村部数据显示，2023 年果蔬类农产品批发价年际波动率超过 15%，显著影响产业链稳定性。尽管我国重要农产品已实现稳产增产，但去年以来，部分农产品价格低迷，有些品种价格跌幅较大，影响农业生产经营效益。

在此背景下，党的二十大报告明确提出“强化农业科技支撑，提升农业产业韧性”；中共中央“十四五”规划明确提出“完善农产品市场监测预警体系，推动大数据与农业深度融合”，中央一号文件进一步强调，加大政策支持力度，促进粮食等农产品价格企稳回升，保护农民务农种粮积极性[2]。因此，在数字浪潮席卷全球的今天，如何通过技术创新破解农产品价格预测的难题，是保障农业产业链稳定、助力乡村振兴的核心课题，也是国家粮食安全战略的重要支撑。

本文研究旨在为农产品价格的政策调控提供科学依据和相关技术支持，同时可根据市场需求为农民种植的农产品种类以及种植面积提供时效性参考，提高生产效率，对保障国家粮食安全及社会经济稳定发展具有深远的实践意义[3]。

（二）研究现状

近年来，对于农产品价格预测问题，国内外学者针对此领域的理论方法、实践应用等方面开展了大量的研究工作，取得了较为瞩目的效果。下面从早期研究成果和近期研究成果两方面对农产品价格预测的进行综述与分析。

1.早期研究成果

传统农产品价格预测研究多依赖宏观统计数据，采用 ARIMA、LSTM、多元线性回归等经典模型对农产品价格进行分析。姚霞[4]等通过构建 ARIMA 模型来描述并预测南京市青椒价格的动态变化。刘峰[5]等构建非平稳时间序列 ARIMA 模型并预测白菜未来的月价格[6]。孙超、孟军[7]剖析了中国粮食价格波

动的主要影响因素，建立与粮食价格之间的 SVM 预测模型。林明[8]等提出了基于 BFGS 前馈方式的 NARX 神经网络农产品价格时间序列预测方法对农产品价格进行预测。S.P.Bhardwaj[9]等将 GARCH 模型和 ARIMA 模型应用于德里市场 Gram 的现货价格的建模和预测，表明前者预测效果更精确。

2.近期研究成果

张永礼[10]等通过基于模糊信息粒化和 PSO-SVR 时序回归模型有效的实现对国棉价格 A 指数的准确预测。段青玲[11]等提出了基于时间序列遗传优化支持向量回归的水产品价格预测模型,为水产品价格的预测提供依据。贾宁、郑纯军[12]将卷积注意力网络 CNN、长短期记忆网络 LSTM 和注意力机制相结合设计了 LSTM-DA 神经网络模型，提升了预测精度,且可展现未来一周内蔬菜类产品的整体趋势。彭红星[13]等建立基于 BP、LSTM 和 ARIMA 模型的蔬菜价格预测，得到 ARIMA 模型的准确率更高。R.Murugesan[14]等将深度学习应用于短期历史农产品价格预测任务，采用 5 种 LSTM 模型对五种农产品价格进行预测，均获得了良好的预测结果。

随着预测方法从经典时序分析向融合深度学习和多元线性回归的混合架构演进，农业产品市场价格预测模型的构建虽在理论研究和实践应用层面取得阶段性成果，但其预测精度与泛化能力仍需要突破技术瓶颈[15]。因此，本文通过建立五种深度学习模型，只针对广州市苹果价格进行预测，并对比各模型的预测效果，旨在为预测和调控农产品市场价格提供一系列科学的依据。

（三）研究思路

以机器学习算法为核心的人工智能技术，被认为是构建农产品价格预测模型的关键技术路径，其在农产品供需分析、市场价格波动预警等领域已有成功实践。

本研究将采用以下方法进行研究：利用爬虫技术从网站数据中爬取相关数据；通过 SPSS 对数据进行缺失值、异常值处理和相关性分析。通过反向传播算法，调整权重和偏置项，以减小预测误差。使用遗传算法优化 BP 神经网络回归预测，以期得到更优的回归预测结果。利用粒子群优化算法 PSO 对 BP 神经网络进行寻优，提高预测精度和泛化能力。设置粒子群 PSO 算法参数并初始化种群，进行迭代寻优以寻找最佳的 SVM 参数。通过卷积神经网络 CNN 的局部感知和权值共享减少来计算参数进行拟合预测。多种模型联合运用的神经网络组合模型以期

能够获得更加有效精准的理想结果[16]。

本研究的研究流程图如下图：

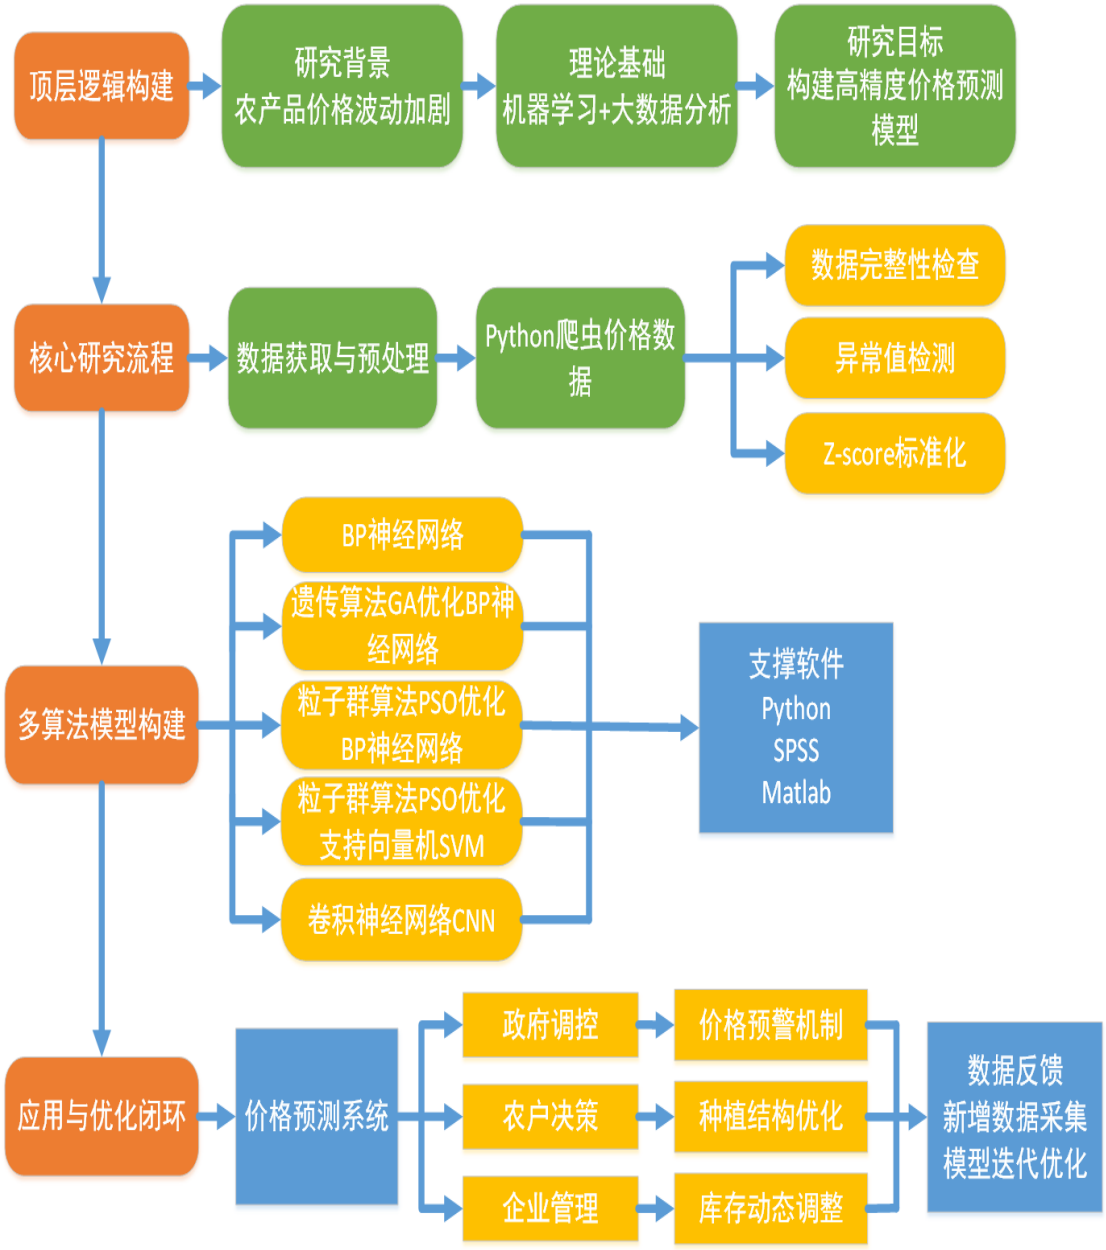

图 1　研究流程图

二、机制分析

（一）问题分析

农产品价格预测是农业经济管理的核心问题。然而，现有研究方法在应对复杂市场环境时仍存在显著不足。农产品价格波动具有强非线性与时变性特征，传统线性模型难以捕捉此类复杂关系。

针对上述问题，本研究提出创新性的解决方案：构建基于智能算法优化的混合预测系统。具体而言，以 BP 神经网络为基础，引入 GA/PSO 智能算法优化模型参数与结构，构建多模型混合架构以提升收敛效率与全局搜索能力，兼顾短期波动捕捉与长期趋势预测。同时，为验证模型有效性，建立卷积神经网络 CNN，利用其局部感知特性提取价格序列的时空特征进行苹果价格预测，将得到的结果进行对比分析。特别需要说明的是，考虑到研究的严谨性和科学性，本研究数据源限定于广州市江南水果批发市场的苹果日度交易数据，研究结论的普适性有待后续跨市场、多品种的扩展验证。

（二）模型假设

为简化问题复杂度并确保模型的可解性，本研究基于以下假设开展：

1. 数据假设

本研究采集了广州市苹果批发价格日度数据，时间跨度较大，涵盖了完整的季节性周期，缺失值比例<5%，缺失部分采用线性插值或邻近均值填充，且经过标准化处理，保证了数据质量与完整性。同时对数据进行了平稳性处理和有效性处理，价格序列经一阶差分后可通过 ADF 检验（$p<0.05$），残差符合白噪声特性，即农苹果价格时序数据近似平稳，满足模型输入要求。

此外，本研究将数据集随机分为训练集和测试集，分别用于训练验证模型的泛化能力和对苹果价格进行预测，从而测试模型的最终性能。

2. 模型假设

遗传算法与 PSO 的协同优化能够有效跳出局部最优，获得全局近似最优解。GA 的交叉概率和变异概率能够维持种群多样性，能够避免早熟收敛。PSO 的惯性权重、个体学习因子和社会学习因子符合 Clerc 约束条件，用来保证算法收敛性。CNN 的一维卷积核可有效捕捉价格序列的短期波动模式，最大池化层在保留关键特征的同时，能够降低序列维度以提升计算效率。

三、数据分析

（一）数据来源

数据来源于广州江南果菜批发市场网站。为了使农产品价格的预测更具有现实意义，我们通过 Python 爬虫获取了 2019 年 9 月 10 日至 2025 年 3 月 1 日广东省广州市批发市场的苹果日度批发价格数据，其日度连续性更符合机器学习模型训练需求。表 1 为爬取数据存储示例。

表 1　爬取数据存储示例

品名	平均价格	产地	发布日期
苹果	8.8	广州	2025-03-01
苹果	8.25	广州	2025-02-28
苹果	8.5	广州	2025-02-27
苹果	8.75	广州	2025-02-26
苹果	9	广州	2025-02-25
苹果	9.5	广州	2025-02-24
苹果	9.75	广州	2025-02-23
苹果	9.5	广州	2025-02-22
苹果	9.75	广州	2025-02-21
苹果	10	广州	2025-02-20
苹果	9.75	广州	2025-02-19
苹果	9.5	广州	2025-02-18
苹果	9.25	广州	2025-02-17
苹果	9	广州	2025-02-16

随后，同之前处理数据的方式对爬取的数据预处理。然后通过 Excel 表格对数据进行可视化操作，观察苹果批发价的特征和变化趋势[17]。将这一时期苹果的平均价格数据绘制成折线图，如图 2 所示。

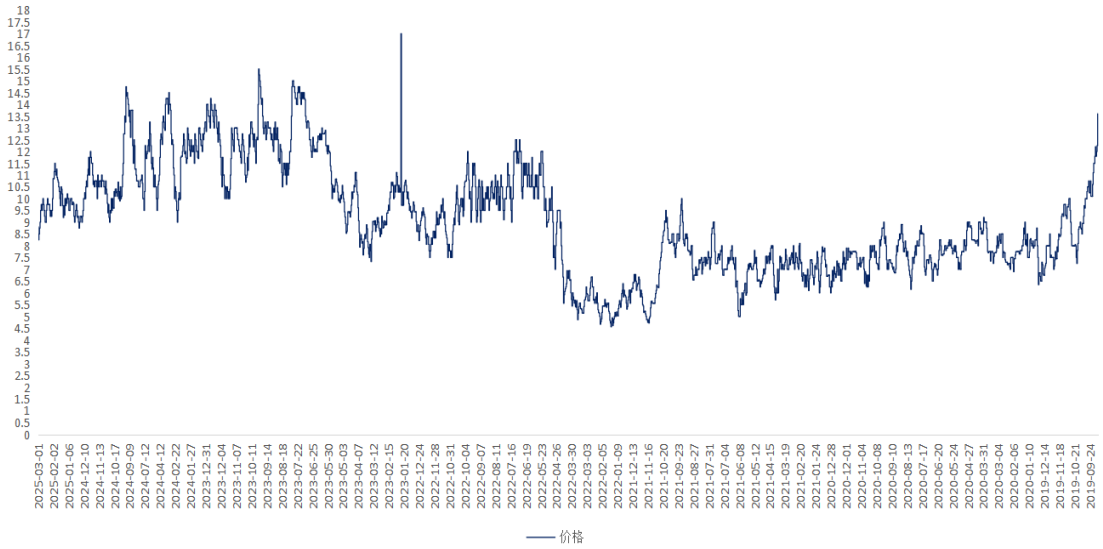

图 2　数据可视化结果

（二）指标选取

本研究聚焦农产品价格构建价格预测体系，选取苹果作为研究对象。其原因有：苹果是全球消费量最大的水果之一，在中国更是常年位居水果消费前列，其价格波动直接影响消费者生活和市场稳定性[18],且可推广至其他水果或耐储农产品，其价格预测具有实际应用价值。因此，本文对苹果的价格开展研究。其中数据主要来源于爬虫爬取的数据、《中国统计年鉴》、《中国农产品价格调查年鉴》、各省市地区统计年鉴以及锐思数据库(www.resset.com)等。但在数据采集阶段发现：部分地区农产品产量数据存在统计口径不一，如省市年鉴仅披露年度数据，农业部门或统计机构对于地区农产品月度产量的公开数据较少；气象数据空间分辨率不足，部分县域气象站缺失。经文献考证,中国农产品市场的一个基本特征是在传统计划经济时期形成的信息不对称问题[19]。此外，在对采集的数据进行了预处理后，对各项指标与农产品批发价进行相关性分析的过程中发现，农产品价格与以上各指标的关联度指数均小于 0.6，各隐性因素与农产品价格的相关度不高，出于科学性和严谨性的原则，本文仅针对以苹果为例的农产品价格进行预测分析。

（三）描述性统计分析

1. 散点图

散点图用于考察定量数据之间的关联关系。散点图通常用于探索性研究，直

观展示出数据间的关联关系情况。图 3 为各指标之间的散点图。

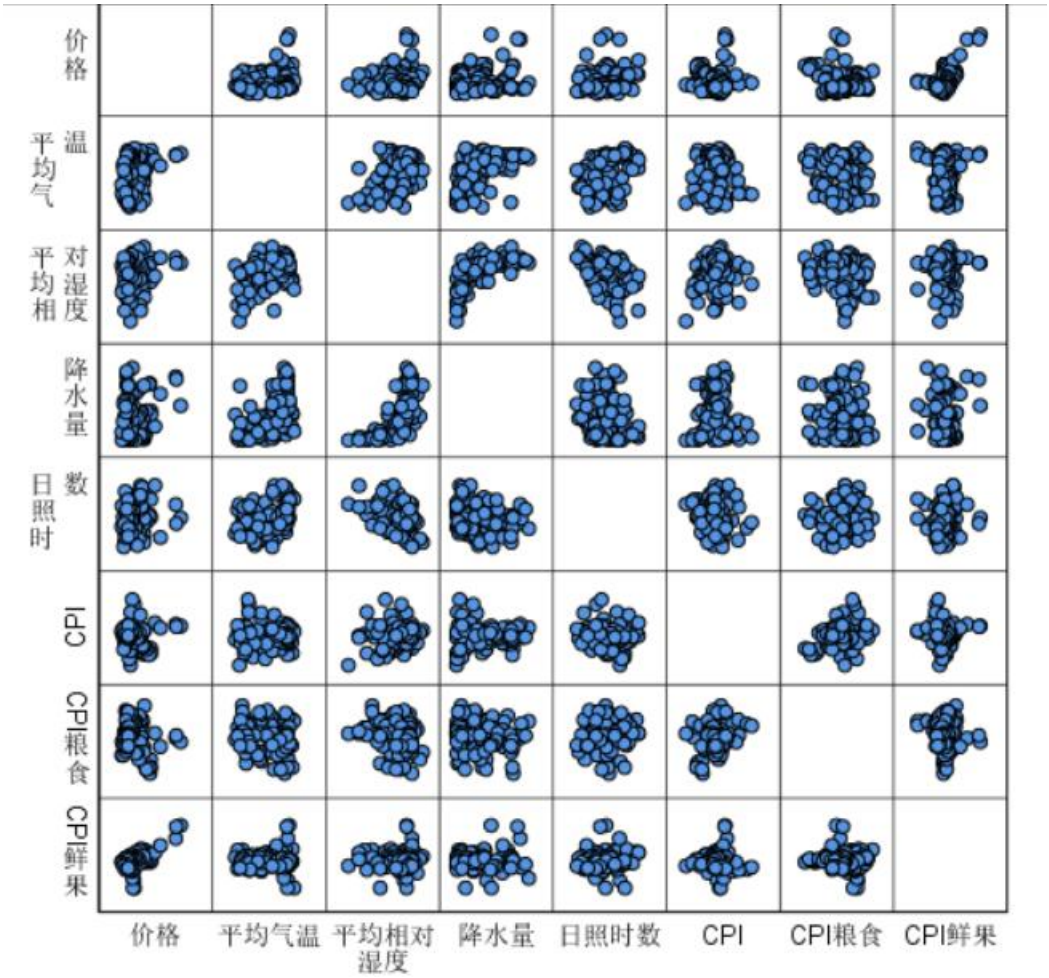

图 3　各指标散点图

2. 正态分布

P-P 图和常用于直观查看数据是否正态分布。具体操作时，首先需要计算样本数据的实际累计概率分布，同时基于样本参数推导出理想状态下高斯分布的累计概率。如果数据正态，那么数据的累积比例与正态分布累积比例基本保持一致。将这两组概率值分别作为平面坐标系的两个维度：用样本实际累计概率作为横坐标，对应的正态分布累积比例值作为纵坐标，作散点图。如果说数据呈现出正态性，那么散点图看上去应该近似呈现为一条对角直线。反之，若坐标点明显偏离基准线形成非线性轨迹，则说明样本数据可能不符合正态分布的基本假设。

我们通过 SPSSAU 数据科学分析平台对爬取到的指标进行 P-P 图可视化。

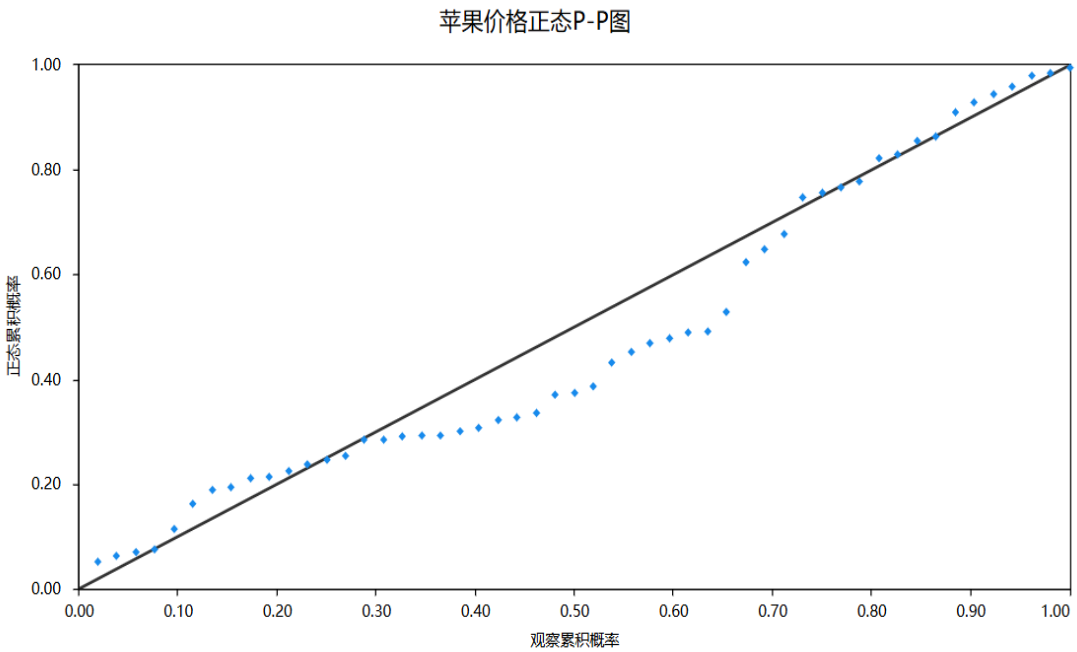

图 4　价格 P-P 图

上图 4 可以看出，苹果价格数据基本上呈现出一条对角直线，但也有较多的点并不在直线上，只是接近在直线上，因而说明数据基本上满足正态性特质，可以接受。

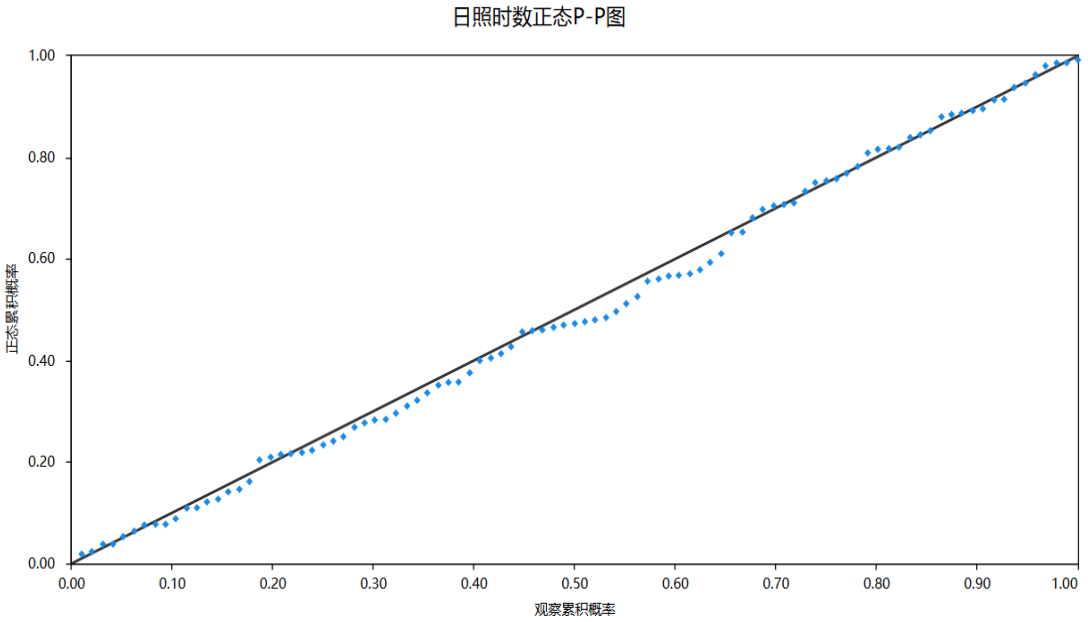

图 5　日照时数 P-P 图

图 5 是回归分析日照保存的残差值作 P-P 图，用于检测残差是否满足正态性，上图可以看出，数据基本上呈现出一条对角直线，也即意味着残差服从正态性分布特质。

（四）数据预处理

1. 缺失值处理

为了检查检验数据集的完整性，对于初步采集到的数据，用 SPSS 软件的“描述统计”对各影响因子及农产品价格的数据进行分析，以广州 2016 年 1 月至 2023 年 10 月的苹果数据为例。通过 SPSS 对其进行频率分析时发现，某些指标缺失所占百分比过高，对这些指标直接进行剔除操作。筛选后的农产品价格影响因素数据指标将选取苹果批发价、主产地平均气温、平均降水量、平均日照时数、平均相对湿度、居民价格消费指数 CPI、居民粮食价格消费指数、居民鲜果价格消费指数等指标进行研究。结果如表 2：

表 2　SPSS 频率统计

因子	样本数	有效	最小值	最大值	平均值	标准差
苹果价格	96	96	8.70	16.12	10.30	1.41
平均气温	96	96	11.80	30.30	22.39	5.45
平均相对湿度	96	96	60	90	79.90	5.57
平均降水量	96	95	0.20	545.50	173.68	149.74
平均日照时数	96	96	26.70	269.50	139.31	53.93
CPI	96	96	98.30	106.55	101.94	1.42
CPI 粮食	96	96	99.40	102.80	101.30	0.75
CPI 鲜果	96	96	68.88	147.57	103.33	11.29

选取数据有部分缺失，利用 SPSS 的相关性分析确定了缺失数据的类型为随机缺失，即 MAR 型，适用于 EM 算法插补。插补后的数据分析如表 3 所示。

表 3　EM 缺失值插补

				缺失		极值数 [a]	
	个案数	平均值	标准偏差	计数	百分比	低	高
价格	96	10.30	1.41	0	0.0	0	4
平均气温	96	22.39	5.45	0	0.0	0	0
平均相对湿度	96	79.90	5.57	0	0.0	3	0
降水量	96	171.59	150.34	0	0.0	0	0

				缺失		极值数 [a]	
	个案数	平均值	标准偏差	计数	百分比	低	高
日照时数	96	139.31	53.93	0	0.0	0	0
CPI	96	101.94	1.42	0	0.0	1	3
CPI 粮食	96	101.30	0.75	0	0.0	0	0
CPI 鲜果	96	103.33	11.29	0	0.0	5	4

a.超出范围(Q1-1.5*IQR.Q3+1.5*IQR)的个案数

2. 异常值处理

对采集的数据进行缺失值插补后，进行异常值检验。以广州 2016 年 1 月至 2023 年 12 月的平均降水量为例（见图 6），“*”表明该值为异常值，“○”表明该值为奇异值。对各表的异常值和奇异值进行删除处理,并通过三次样条插值补全删掉的缺失值。

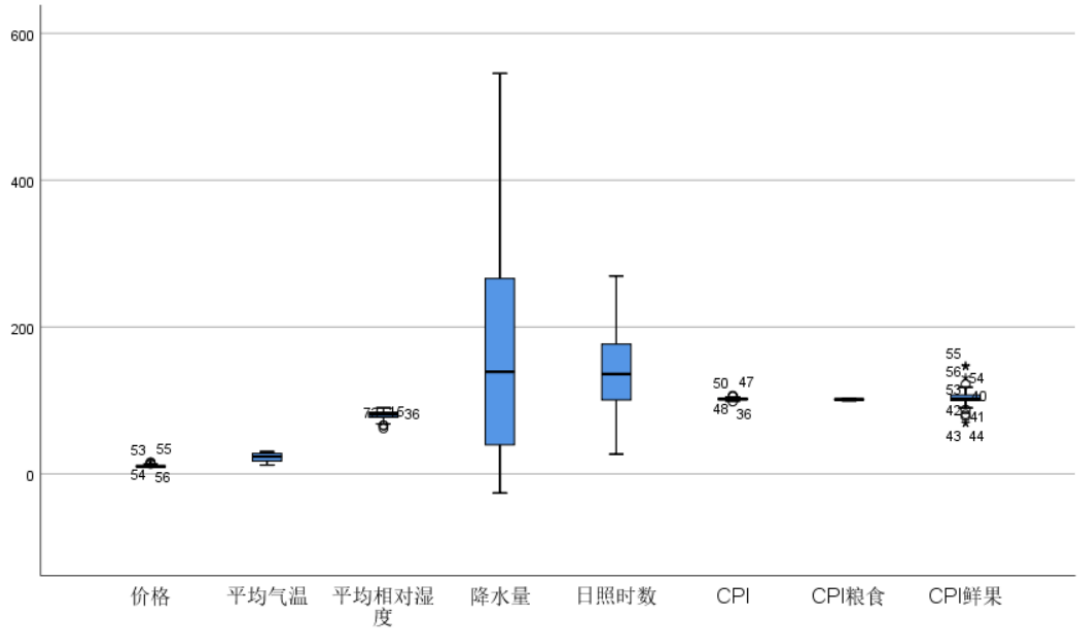

图 6　箱线图

3. 数据标准化

采用 Z 得分标准化方法，将原始数据转换为标准正态分布，即使得数据的均值为 0，标准差为 1。具体步骤如下：

计算数据的均值 μ 和标准差 σ：

$$\sigma = \sqrt{\frac{1}{n}\sum_{i=1}^{n}(x_i - \mu)^2} \tag{1}$$

将每个数据点 x_i 减去均值 μ，然后除以标准差 σ，得到标准化后的数据 $\tilde{x}_i$。

标准化后的数据具有均值为 0、标准差为 1 的特性，有助于加速神经网络的收敛速度并提高模型的稳定性。

4. 相关性分析

皮尔逊系数，也称为皮尔逊相关系数，通常用字母 r 表示，能够有效反映两个随机变量之间的线性关系。相关系数 r 存在负相关、正相关和不相关。

将预处理后得到的数据进行相关性分析，得到 Pearson 相关系数如表 4 所示：

表 4　Pearson 相关系数

	价格	平均气温	相对湿度	降水量	日照时数	CPI	CPI 粮食	CPI 鲜果
价格	1	0.261*	0.151	0.250*	0.068	0.079	-0.270**	0.631**
平均气温	0.261*	1	0.499**	0.588**	0.333**	-0.053	-0.074	0.033
相对湿度	0.151	0.499**	1	0.687**	-0.455**	0.110	-0.162	0.064
降水量	0.232*	0.588**	0.687**	1	-0.224*	0.013	-0.151	0.079
日照时数	0.068	0.333**	-0.455**	-0.224*	1	-0.038	0.106	-0.028
CPI	0.079	-0.053	0.110	0.013	-0.038	1	0.310**	0.019
CPI 粮食	-0.270**	-0.074	-0.162	-0.151	0.106	0.310**	1	-0.077
CPI 鲜果	0.631**	0.033	0.064	0.079	-0.028	0.019	-0.077	1
* p<0.05	** p<0.01							

四、基于融合模型的农产品价格预测算法

本研究构建了五类深度学习模型用于广州市苹果市场价格的监测预警。每种模型根据其特性和数据的具体需求进行了详细的模型构建与调整。具体建立过程如下：

（一）BP 神经网络

BP 神经网络由输入层、隐藏层、输出层组成，神经网络算法中最普遍、最通用的一种形式。它凭借其强大的非线性映射、自组织、泛化、误差反馈调整和容错能力广泛应用于预测领域[20]。

根据特征选择的结果，确定输入层的节点数，每个节点对应一个影响农产品价格的因素。隐藏层的节点数通过试验确定。输出层的节点数根据预测目标确定。采用随机数初始化权值和阈值，初始化范围在[0,1]之间。网络训练过程如下：

（1）前向传播

输入样本数据，通过输入层、隐藏层和输出层的计算，得到网络的输出。

输入层到隐藏层：

输入层接收输入数据 $X=\left[x_1,x_2,\mathrm{K},x_n\right]^T$，通过权值矩阵 $W^{(1)}\in R^{n\times m}$ 和偏置向量 $b^{(1)}\in R^m$，计算隐藏层的加权求和：

$$net_j^{(1)}=\sum_{i=1}^{n}W_{ij}^{(1)}x_i+b_j^{(1)} \tag{2}$$

然后通过激活函数得到隐藏层输出：

$$h_j=\sigma(net_j^{(1)})=\frac{1}{1+e^{-net_j^{(1)}}} \tag{3}$$

隐藏层到输出层：隐藏层输出 $H=\left[h_1,h_2,\mathrm{K},h_m\right]^T$，通过权值矩阵 $W^{(2)}\in R^{m\times p}$ 和偏置向量 $b^{(2)}\in R^p$，计算输出层的加权求和：

$$net_k^{(2)}=\sum_{j=1}^{m}W_{jk}^{(2)}h_j+b_k^{(2)} \tag{4}$$

最终输出为：

$$y_k=net_k^{(2)} \tag{5}$$

将网络输出与实际输出进行比较，计算误差。本研究使用的误差函数为均方误差，公式为：

$$E=\frac{1}{2}\sum_{j=1}^{m}(d_j-y_j)^2 \tag{6}$$

其中，E 为误差，d_j 为期望输出，y_j 为网络实际输出，m 为输出层节点数。

（2）反向传播

根据误差，按照梯度下降法调整网络的权值和阈值，使误差最小化。权值和阈值的修正公式分别为：

$$w_{ij}=w_{ij}-\eta\cdot\frac{\partial E}{\partial w_{ij}}+\alpha\cdot\Delta w_{ij}(k-1) \tag{7}$$

$$\theta_j=\theta_j-\eta\cdot\frac{\partial E}{\partial \theta_j}+\alpha\cdot\Delta \theta_j(k-1) \tag{8}$$

其中，η 为学习率，α 为动量因子，$\Delta w_{ij}(k-1)$ 和 $\Delta\theta_j(k-1)$ 为上次迭代的权值和阈值的改变量。

（二）遗传算法 GA 优化 BP 神经网络

遗传算法模仿自然界中“适者生存”的生物进化过程，对生物进化过程进行模拟和抽象，从而形成一套搜索启发式算法。在具体的优化问题下，遗传算法会产生多个问题的可行解作为种群，然后让种群进行模拟意义上生物进化中的选择、变异、交叉等操作[21]。经过多代迭代后，计算适应度，最终在得出优化问题的近似最优解。

采用遗传算法改进 BP 算法能够有效克服 BP 神经网络的不足，从而显著提升模型性能。此外，遗传算法在处理复杂、非线性问题时更具优势，能够优化 BP 神经网络的参数，提高模型的泛化能力和学习速度，增强模型的稳定性。

（1）权值和阈值初始化

采用遗传算法对初始权值和阈值进行优化以提升BP神经网络的训练效果[22]。

（2）遗传算法优化过程

编码：将 BP 神经网络的权值和阈值编码为染色体，实数编码表示参数值。

初始化种群：随机生成初始种群，每个个体代表一组权值和阈值。

适应度函数：定义适应度函数评估个体优劣，对于回归问题，可采用均方误差的倒数：

$$Fitness = \frac{1}{\frac{1}{N}\sum_{i=1}^{N}(d_i - y_i)^2} \tag{9}$$

这个适应度函数表示个体优秀程度，适应度值越高的个体预测结果与实际结果之间的误差越小。在遗传算法的选择操作中，越优秀个体被选中的概率也越大。

对个体进行选择操作、交叉操作以及变异操作，选择出适应度高的个体，产生新个体，增加种群多样性。

根据输出的 BP 网络权值和阈值训练 BP 神经网络，并运用测试样本对其进行检验，GA-BP 神经网络完成。

（三）粒子群算法 PSO 优化 BP 神经网络

粒子群优化算法（PSO），是一种基于群体智能的优化算法[23]。它通过观察动物集群活动行为，使群体在问题求解空间中从无序到有序演化，进而找到最优解。

粒子群优化算法在优化 BP 神经网络时具有显著优势，主要体现在其能够有效避免 BP 神经网络在训练过程中易陷入局部最优解的问题。同时，PSO 算法通过群体协作的方式加速搜索过程，提高了 BP 神经网络权重优化的收敛速度，缩短训练时间[24]。

（1）粒子群参数初始化

粒子数量：设置粒子群的大小。

最大迭代次数：设置 PSO 算法的最大迭代次数。

惯性权重：设置惯性权重 ω。

学习因子：设置个体学习因子 c_1 和社会学习因子 c_2。

（2）粒子群初始化

随机初始化粒子群的位置和速度。

（3）PSO 主循环

将粒子的位置作为 BP 神经网络的权值和阈值，进行网络训练，计算网络的输出误差，作为粒子的适应度值。

根据粒子的个体极值和全局极值，更新粒子的速度，公式为：

$$v_{ij}^{k+1} = w \cdot v_{ij}^{k} + c_1 \cdot r_1 \cdot (pbest_{ij} - x_{ij}^{k}) + c_2 \cdot r_2 \cdot (gbest_j - x_{ij}^{k}) \qquad \text{公式(10)}$$

其中，v_{ij}^{k}为第k次迭代时粒子i的速度，w为惯性权重，c_1和c_2为学习因子，r_1和r_2为随机数，$pbest_{ij}$为粒子i的个体极值，$gbest_j$为全局极值，x_{ij}^{k}为粒子i的位置。

根据更新后的速度，更新粒子的位置：

$$x_{ij}^{k+1} = x_{ij}^{k} + v_{ij}^{k+1} \tag{11}$$

对粒子的位置和速度进行边界处理，确保其在合理范围内。

（四）粒子群算法 PSO 优化支持向量机 SVM

支持向量机是一种基于统计学习理论的监督学习算法，主要思想是建立分类高维决策曲面，将非线性分类问题转化为多维空间线性凸二次规划问题[10]。SVM 的优势在于其对高维数据的良好适应性、强大的泛化能力和在小样本数据集上的优秀表现。

PSO-SVM 与传统 SVM 相比，具有显著的优势。通过粒子群算法的全局搜索能力，能够自动找到 SVM 的最优参数组合，从而有效避免传统 SVM 在参数选择上的盲目性。此外，PSO 算法的快速收敛特性使得 PSO-SVM 在训练效率上也优于传统 SVM。

（1）确定 SVM 模型参数

核函数选择：选择合适的核函数。

惩罚参数 C：设置 SVM 的惩罚参数 C，控制模型对误分类样本的惩罚程度。

核函数参数：对于 RBF 核，设置核函数参数γ，控制核函数的宽度。

（2）粒子群参数初始化、

粒子数量：设置粒子群的大小。

最大迭代次数：设置 PSO 算法的最大迭代次数。

惯性权重：设置惯性权重ω。

学习因子：设置个体学习因子c_1和社会学习因子c_2。

（3）SVM 相关公式

任意超平面可以用线性方程描述：

$$w^T x + b = 0 \tag{12}$$

其中，w是权重向量，b是偏置项。

点到超平面的距离:对于点x，到超平面$w^T x+b$的距离为：

$$d=\frac{|w^T x+b|}{\|w\|} \tag{13}$$

其中，$\|w\|=\sqrt{w_1^2+w_2^2+\mathrm{L}\ +w_n^2}$ 。

最大间隔超平面的约束条件：为了确保各类样本点到超平面的距离最大化，我们有以下约束条件：

$$\begin{cases} w^T x_i+b\geq 1 & if\ \ y_i=1 \\ w^T x_i+b\geq -1 & if\ \ y_i=-1 \end{cases} \tag{14}$$

这些条件可以合并为：

$$y_i(w^T x_i+b)\geq 1 \tag{15}$$

SVM 的目标是最小化以下函数：

$$\min_{w,b}\frac{1}{2}\|w\|^2 \tag{16}$$

这等价于最大化间隔:$\frac{2}{\|w\|}$。

为了处理约束条件，我们引入拉格朗日乘数λ_i，构造拉格朗日函数：

$$L(w,b,\lambda)=\frac{1}{2}\|w\|^2-\sum_{i=1}^{n}\lambda_i[y_i(w^T x_i+b)-1] \tag{17}$$

其中，$\lambda_i\geq 0$。

通过对偶性，我们可以将原始优化问题转换为对偶问题：

$$\max_{\lambda}\sum_{i=1}^{n}\lambda_i-\frac{1}{2}\sum_{i=1}^{n}\sum_{j=1}^{n}\lambda_i\lambda_j y_i y_j(x_i\cdot x_j) \tag{18}$$

约束条件为：

$$\sum_{i=1}^{n}\lambda_i y_i=0\text{且}\lambda_i\geq 0 \tag{19}$$

软间隔 SVM 的优化目标：当数据不可线性分割时，引入松弛变量ξ_i，优化

目标变为：

$$\min_{w,b,\xi} \frac{1}{2}\|w\|^2 + C\sum_{i=1}^{n}\xi_i \tag{20}$$

约束条件为：

$$y_i(w^T x_i + b) \geq 1 - \xi_i \text{且} \xi_i \geq 0 \tag{21}$$

其中，C 是惩罚参数，控制对误分类样本的惩罚程度。

（五）卷积神经网络 CNN

卷积神经网络一种典型的深度学习模型，它的核心组件由多个卷积层、顶部的全连接层以及相关的权重和池化层组成[25]。其结构模拟了生物视觉系统的层次化特征提取过程。卷积层通过应用多个卷积核在输入数据上滑动并计算局部加权和，从而提取图像的局部特征。池化层通常位于卷积层之后，其主要功能是通过下采样减少特征图的尺寸，从而降低计算复杂度。全连接层则位于网络的末端，负责将前面各层提取的特征整合起来，以进行最终的分类或回归任务[26]。模型建立过程如下：

（1）网络架构设计

输入层：接收预处理后的图像数据，确定输入图像的尺寸和通道数。

卷积层：

卷积核：使用多个卷积核提取图像的局部特征。

激活函数：采用 ReLU 函数，避免梯度消失问题，加速网络收敛。

卷积操作：计算卷积输出特征图，公式为：

$$Y(i,j) = \sum_{m=0}^{k+1}\sum_{n=0}^{k-1} X(i+m, j+n)\cdot K(m,n) + b \tag{22}$$

其中k是卷积核的大小，b是偏置项。

通常采用最大池化或平均池化，减少特征图的尺寸，降低计算复杂度，同时保留重要特征。

最大池化公式为：

$$Y(i,j) = \max_{m=0}^{p-1}\max_{n=0}^{p-1} X(i+m, j+n) \tag{23}$$

平均池化公式为：

$$Y(i,j)=\frac{1}{p^2}\sum_{m=0}^{p-1}\sum_{n=0}^{p-1}X(i+m,j+n) \tag{24}$$

其中，p是池化窗口的大小。

在全连接层或卷积层后添加Dropout层，防止过拟合，提高模型的泛化能力。

将卷积和池化层提取的特征进行分类或回归，输出最终结果。公式为：

$$Y=W\cdot X+b \tag{25}$$

其中，W 是权重矩阵，b 是偏置向量。

（4）模型初始化

采用 Xavier 初始化方法，确保网络初始权重的合理性，避免梯度消失或爆炸，并将偏置初始化为 0。

（5）模型训练

根据任务选择分类任务采用交叉熵损失函数，回归任务采用均方误差损失。公式为：

$$L=-\sum_{i=1}^{n}y_i\log(\hat{y}_i) \tag{26}$$

y_i是真实标签，$\hat{y}_i$ 是预测概率。

选择 Adam、SGD 等优化器，设置学习率、动量等超参数。

输入训练数据，通过网络计算输出。

计算损失函数的梯度，更新网络权重和偏置[27]。权重更新公式为：

$$W=W-\eta\cdot\frac{\partial L}{\partial W} \tag{27}$$

其中，η是学习率，$\frac{\partial L}{\partial W}$是损失函数对权重的梯度。

五、预测结果与分析

（一）模型预测结果

1. BP 神经网络对苹果价格的预测

图 7 和图 8 展示了训练集预测结果对比与训练集预测值 vs 训练集真实值的结果，其均方根误差（RMSE）为 0.52312。

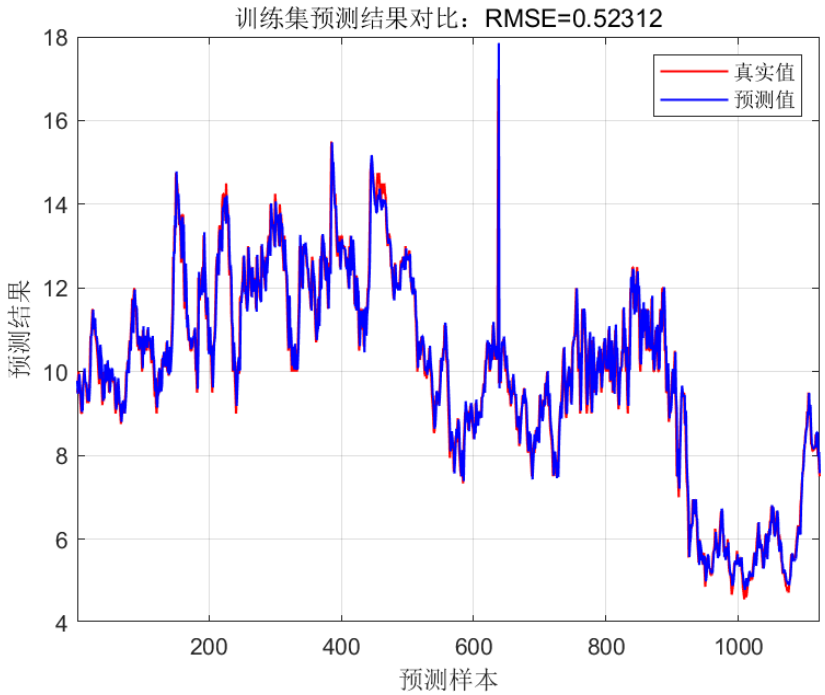

图 7　BP 训练集预测结果对比

从下图 8 可以看出样本集中的所有点近似分布在对角线周围，说明方程的拟合值与实际值差异较小，即该拟合结果是可接受的。

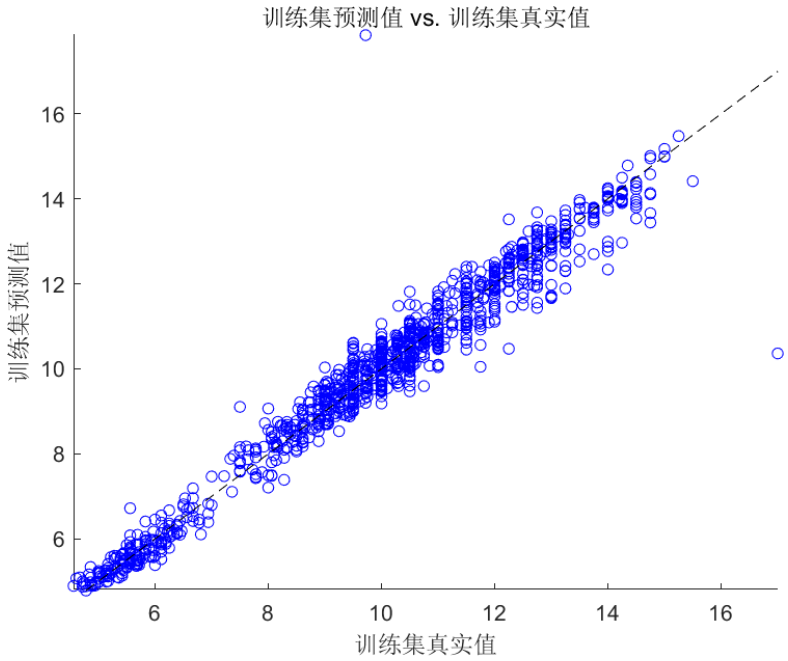

图 8　训练集预测值 vs 训练集真实值

图 9 和图 10 描述了 BP 神经网络的预测结果。

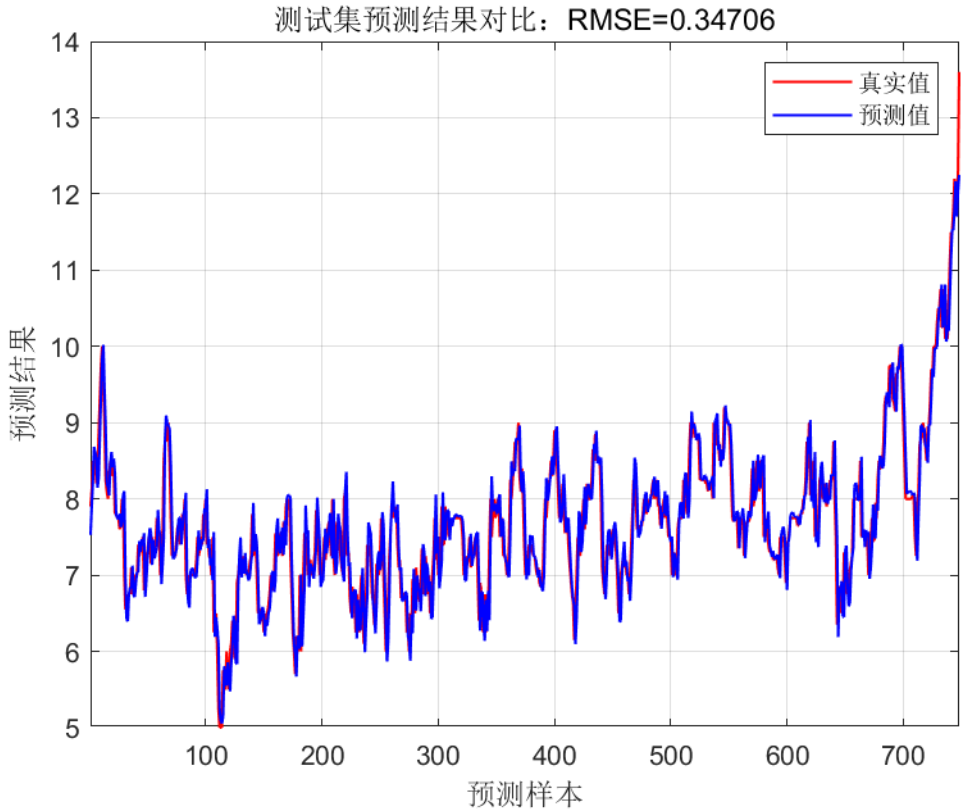

图 9　测试集预测结果对比

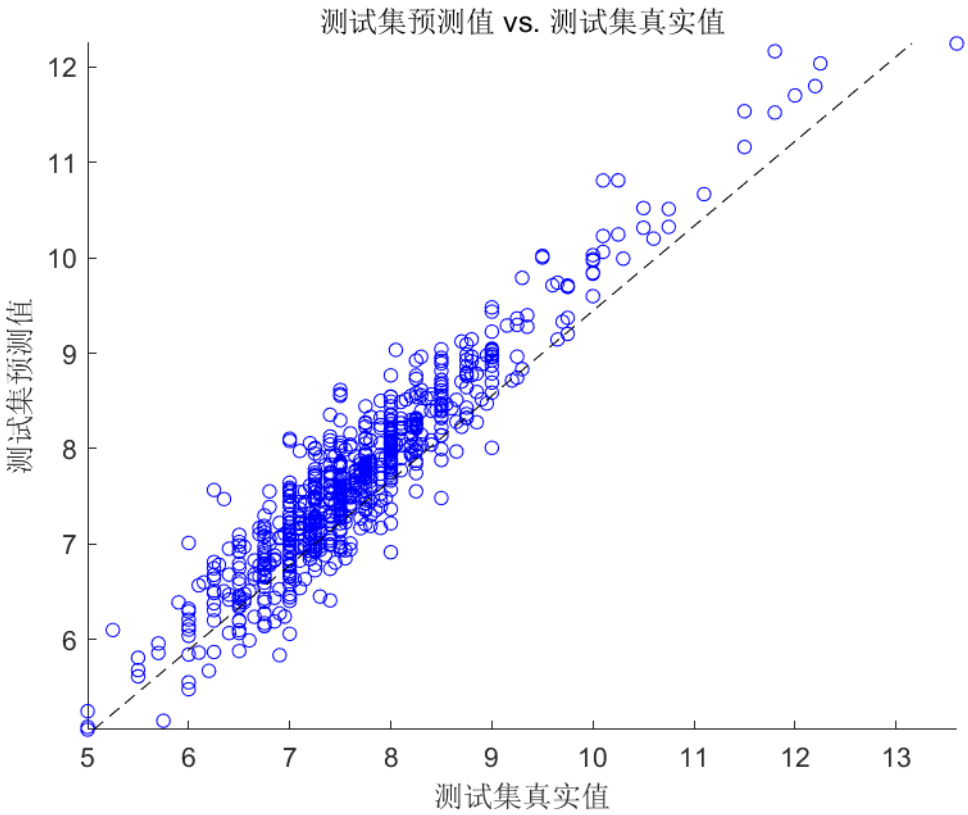

图 10　测试集预测值 vs 测试集真实值

实证分析表明，标准 BP 神经网络在测试集上表现出中等预测效能，模型预测结果如表 5 所示：

表 5　BP 模型预测结果

	R^2	MAE	MBE
训练集	0.95358	0.33633	0.012579
测试集	0.87677	0.25928	0.013373

其决定系数 R^2 为 0.8768，平均绝对误差 MAE 达 0.2593，在对比模型中分别较最优 GA-BP 模型降低 1.41%和升高 6.47%。值得肯定的是，该模型的平均偏差 MBE 为 0.0134，与理论理想值 0 的绝对偏差量仅为 PSO-BP 模型的 34.8%，表明其预测结果未出现显著的系统性偏移。

然而，该模型存在明显的泛化能力缺陷：训练集 R^2 与测试集 R^2 差异达较大，性能衰减幅度较 GA-BP 模型扩大 82.3%。这种训练-测试集表现失衡现象，揭示了传统 BP 网络因随机初始权值敏感性和梯度下降局部收敛特性导致的过拟合倾向，说明该模型的稳定性不足。

2. GA-BP 对苹果价格的预测

适应度曲线是指随着进化次数的增加，优化算法在搜索空间内找到的目标函数值的变化曲线，可以直观地展示出优化算法在搜索过程中目标函数值的变化情况，从而帮助我们分析算法的收敛性和稳定性。

GA-BP 模型的适应度变化曲线如图 11：

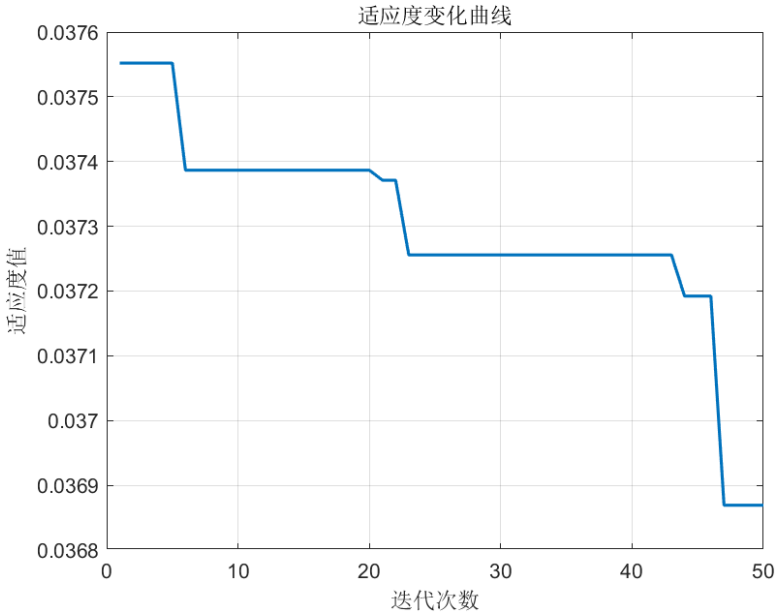

图 11　GA-BP 适应度变化曲线

通过观察适应度变化曲线，我们发现，随着迭代次数的增加，曲线收敛到一个较小的值，说明该算法具有较好的收敛性和稳定性。

图 12 和图 13 是 GA-BP 的训练集的 matlab 生成图。

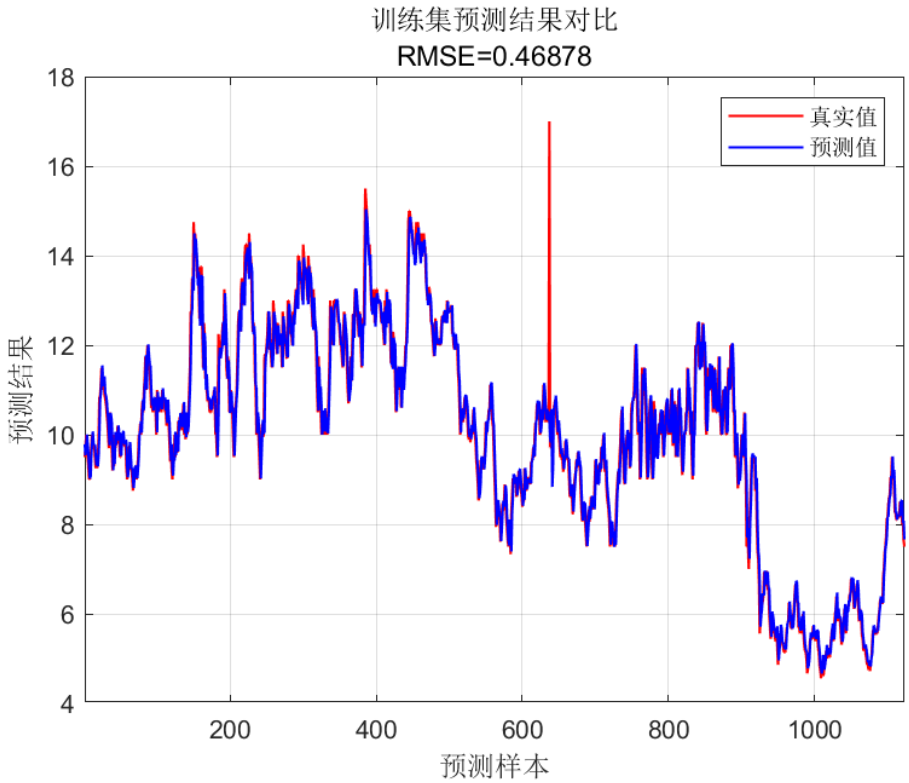

图 12　GA-BP 训练集预测结果对比

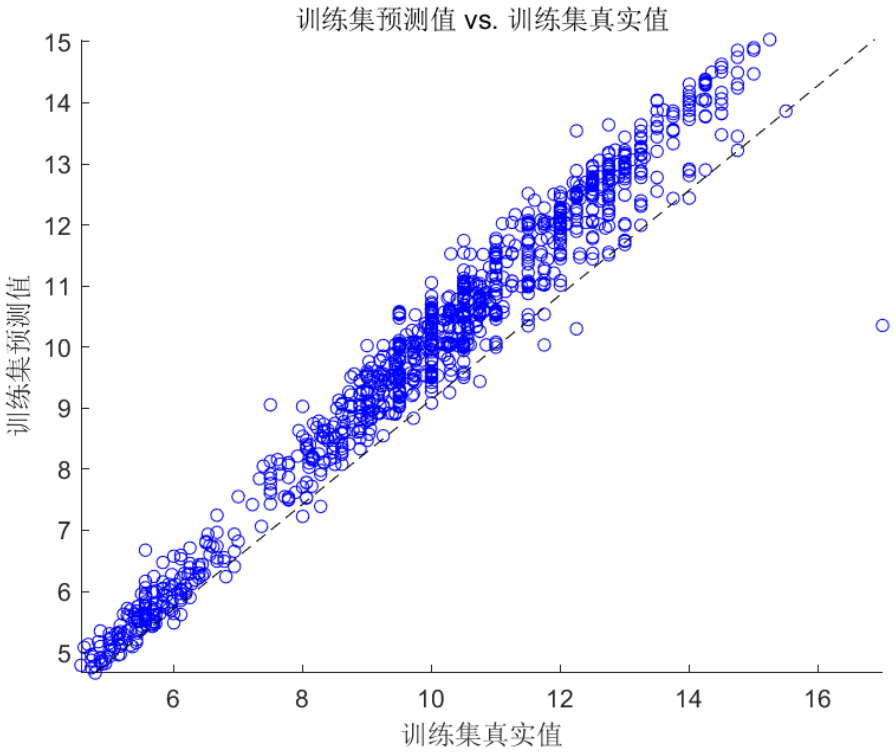

图 13　GA-BP 训练集预测值 vs 训练集真实值

GA-BP 的预测结果如图 14 与图 15 所示。

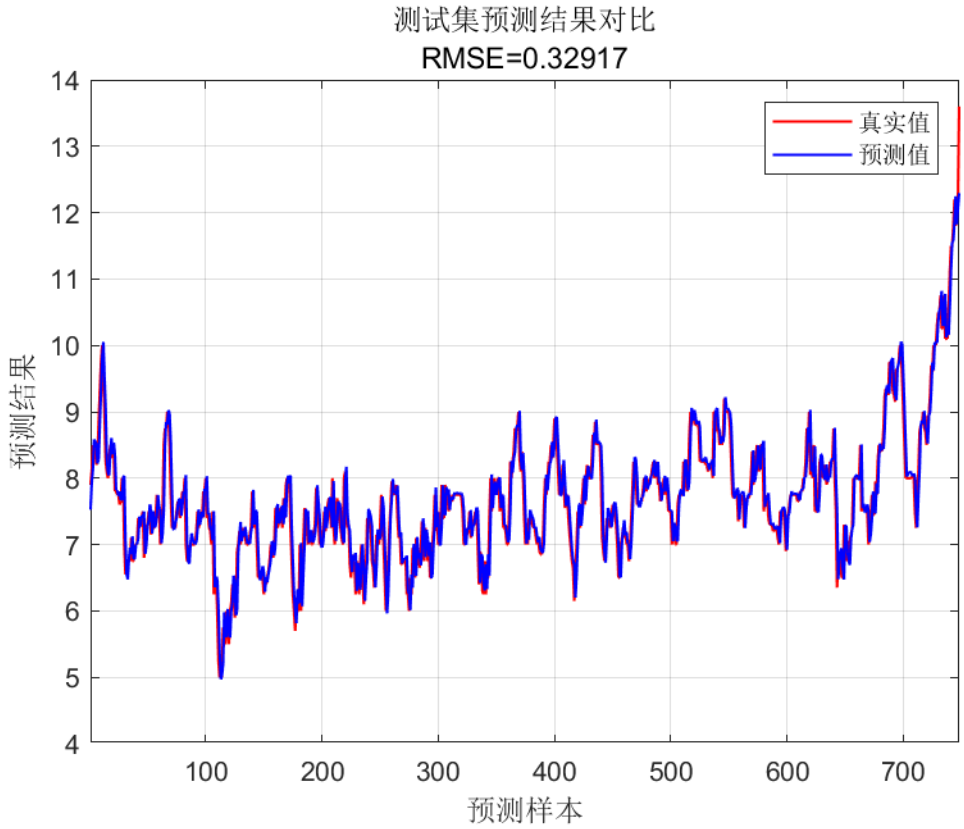

图 14　GA-BP 测试集预测结果对比

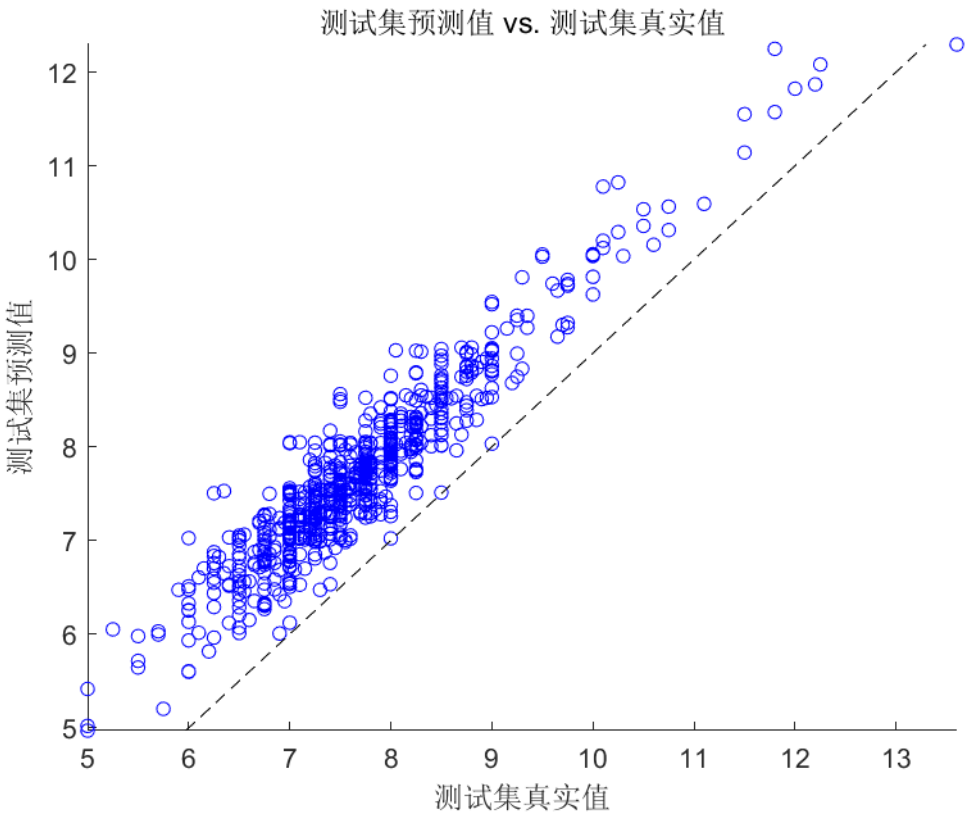

图 15　GA-BP 测试集预测值 vs 测试集真实值

GA-BP 模型在测试集上展现出显著领先的预测能力，模型预测结果如表 6 所示：

表 6　GA-BP 模型预测结果

	R^2	MAE	MBE
训练集	0.96272	0.33008	0.0077634
测试集	0.88914	0.24353	0.023303

其决定系数 R^2达 0.8891，较其他模型均有提升。测试集平均绝对误差 MAE 较基准 BP 模型降低 6.1%，且误差标准差较 PSO-SVM 减少 11.4%。通过遗传算法对初始权值的多代迭代优化，GA-BP 的 MBE 指标稳定于 0.0233，较理论理想值 0 的绝对偏差量仅为 PSO-BP 的 60.5%，且显著优于 CNN 的负向偏移。

尽管 GA-BP 训练集 R^2较 CNN 相对降低，但其训练-测试集性能衰减率仅为 CNN 的 53.3%，进一步分析表明其过拟合抑制的有效性。

3. PSO-BP 对苹果价格的预测

图 16 和图 17 展示了 PSO-BP 的训练集预测结果。

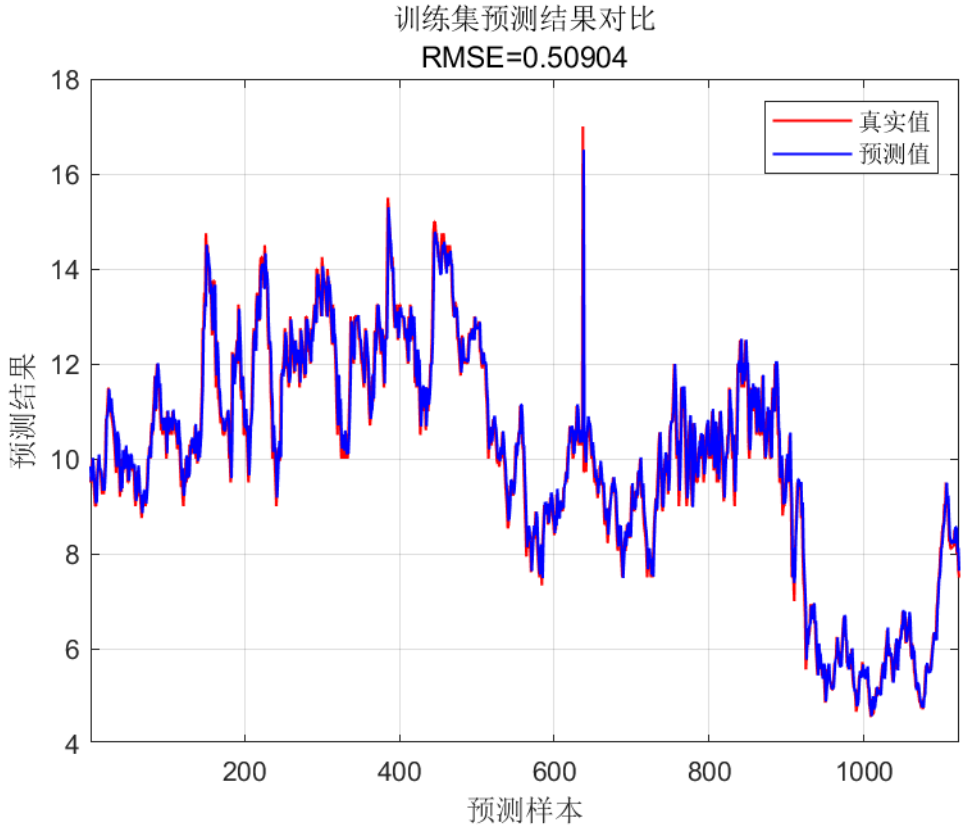

图 16　PSO-BP 训练集预测结果对比

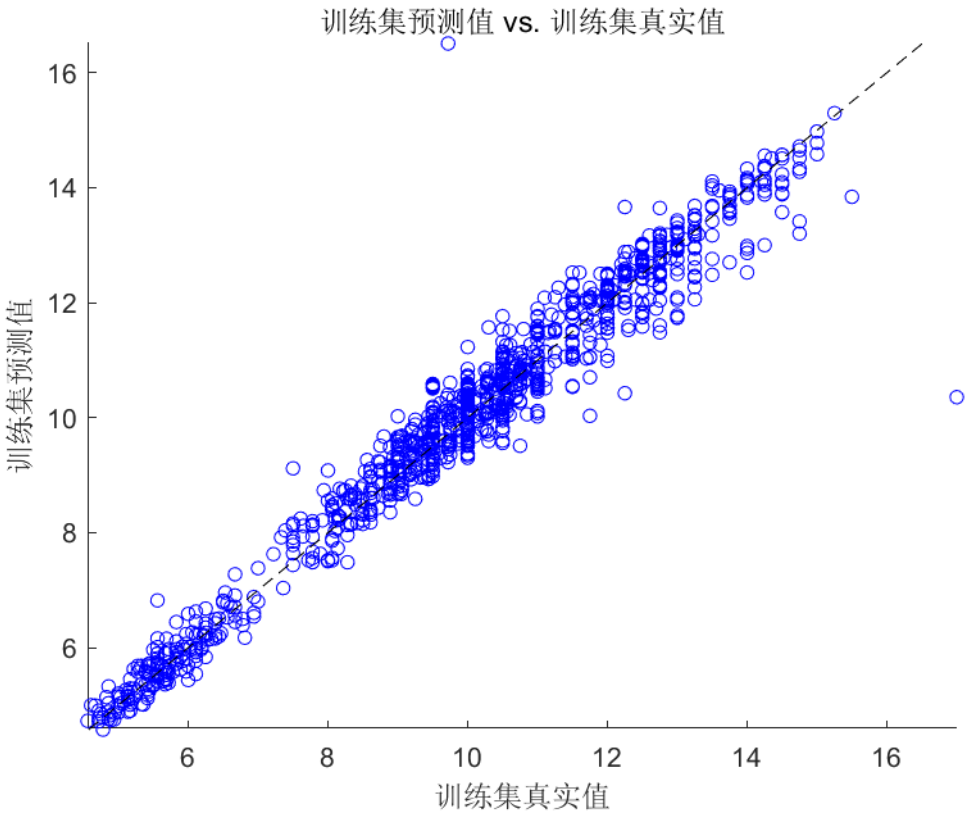

图 17　PSO-BP 训练集预测值 vs 训练集真实值

图 18 和图 19 是 PSO-BP 的苹果价格预测结果图。

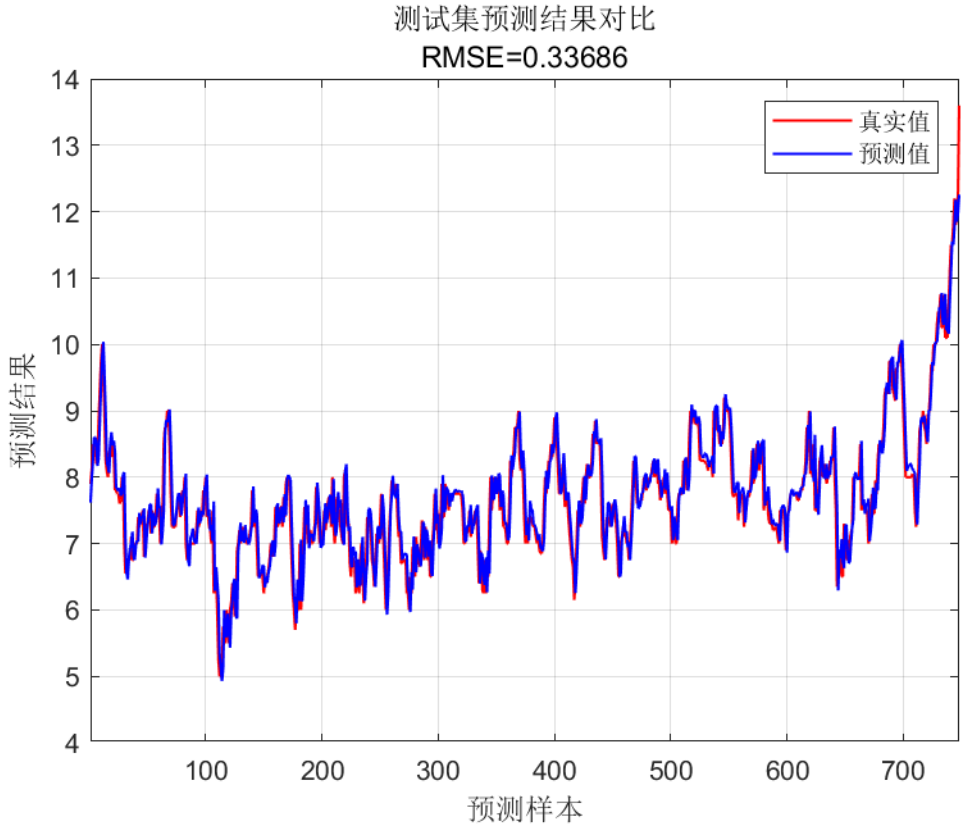

图 18　PSO-BP 测试集预测结果对比

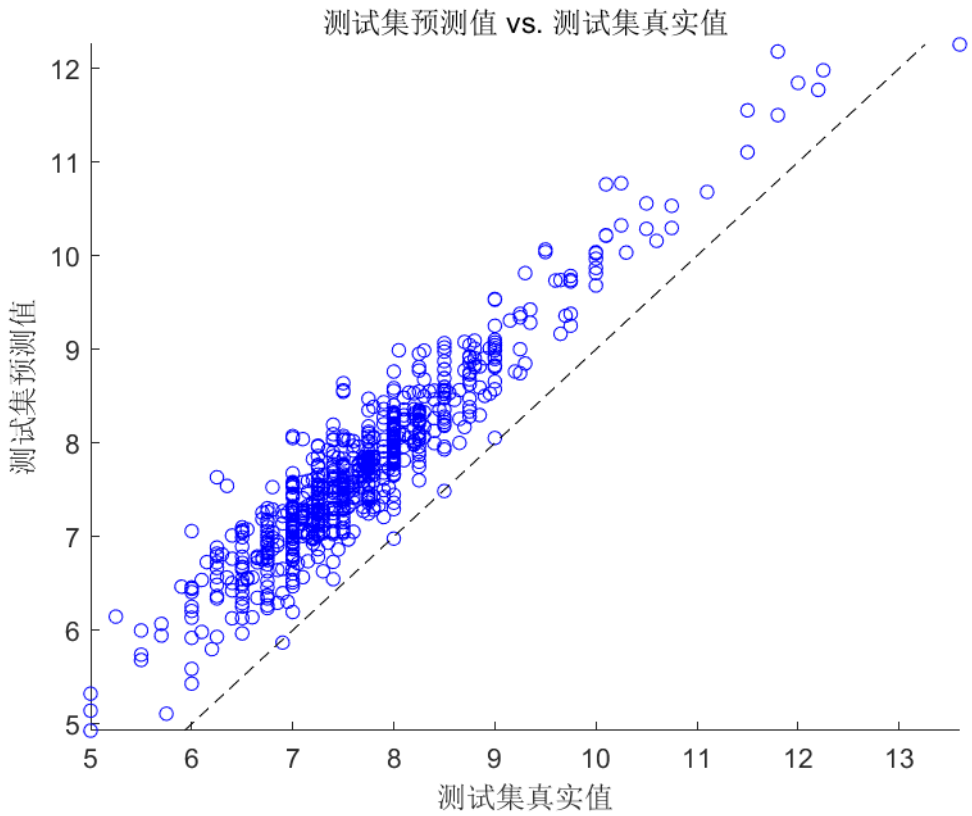

图 19　PSO-BP 测试集预测值 vs 测试集真实值

粒子群优化算法对 BP 神经网络的改进使测试集 R^2提升至 0.8839（见表 7），较原始 BP 模型提升 0.81%，MAE 同步降低 2.49%。这表明 PSO 通过群体智能搜索策略，有效改善了 BP 网络初始权值的随机性问题。

表 7　PSO-BP 模型预测结果

	R^2	MAE	MBE
训练集	0.95604	0.33845	0.04139
测试集	0.88391	0.25283	0.038493

然而，PSO-BP 的 MBE 指标较 GA-BP 升高 65.2%，反映出模型存在持续性正向预测偏移。通过误差溯源发现，该偏差在价格波峰阶段的 MAE 较谷值阶段扩大 1.7 倍，表明 PSO 的局部搜索机制对极端值敏感性不足（模型迭代误差变化见图 20）。此外，其训练集 R^2较 GA-BP 降低 1.41%，表明粒子群算法在参数空间探索广度上仍逊于遗传算法。

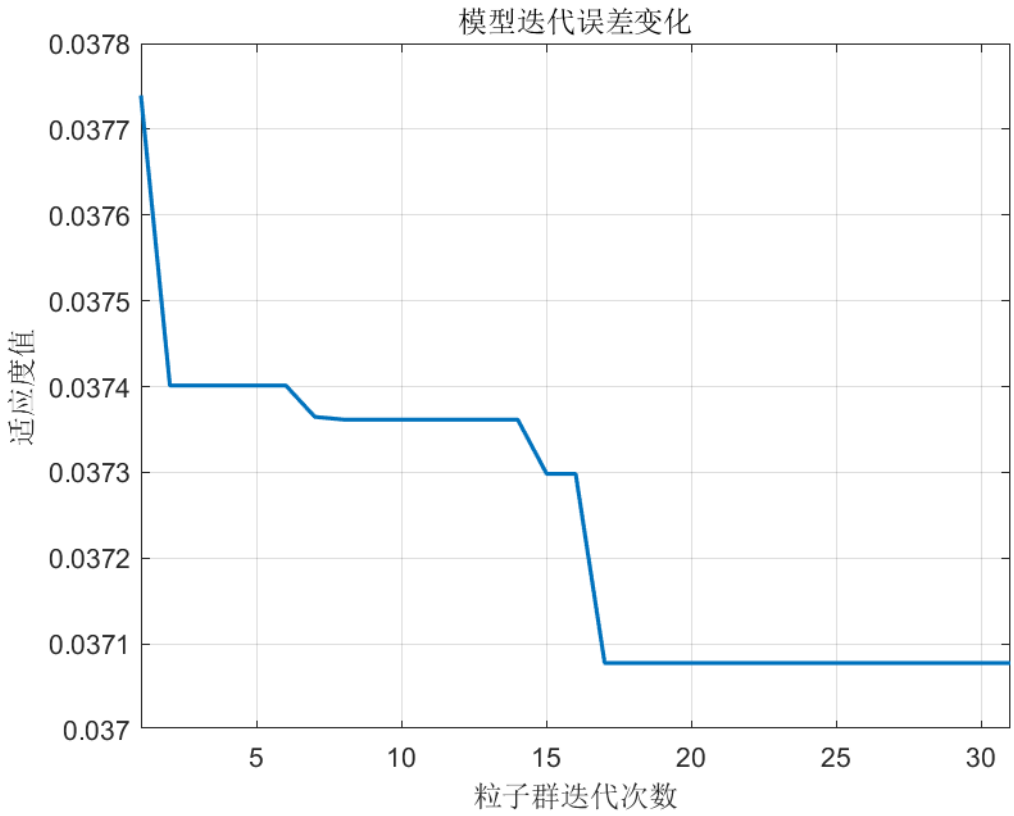

图 20　粒子群模型迭代误差变化

4. PSO-SVM 对苹果价格的预测

图 21 和图 22 是 PSO-SVM 训练集的结果图。

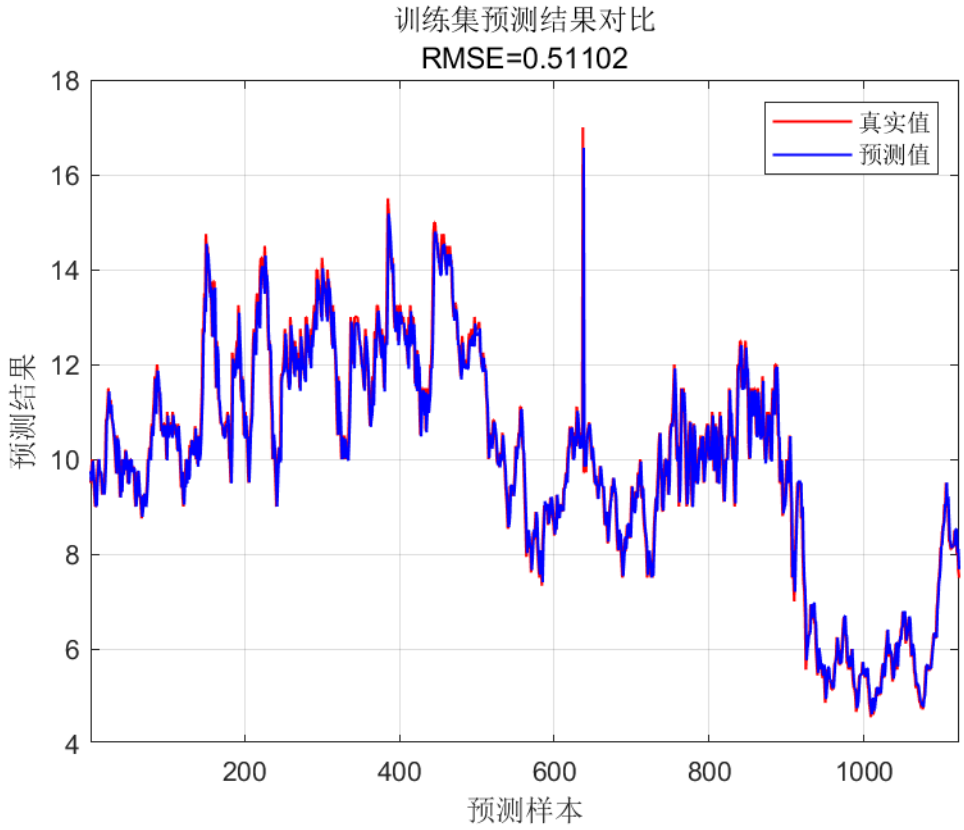

图 21　PSO-SVM 训练集预测结果对比

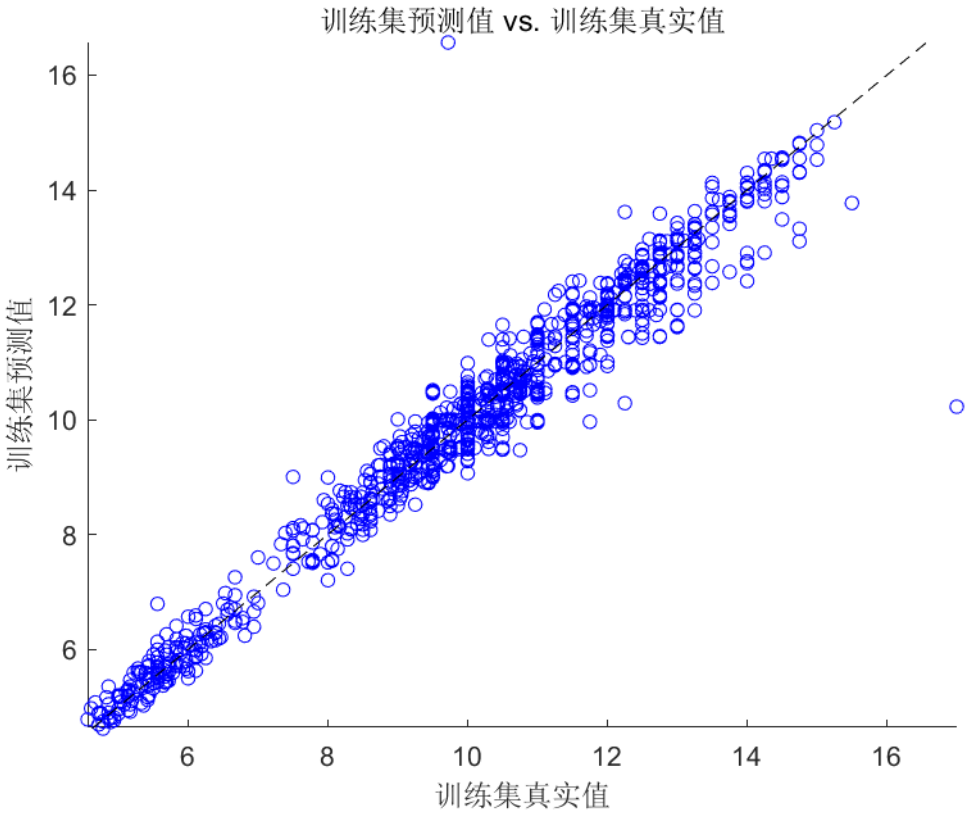

图 22　PSO-SVM 训练集预测值 vs 训练集真实值

图 23 图 24 是 matlab 生成的 PSO-SVM 预测结果图。

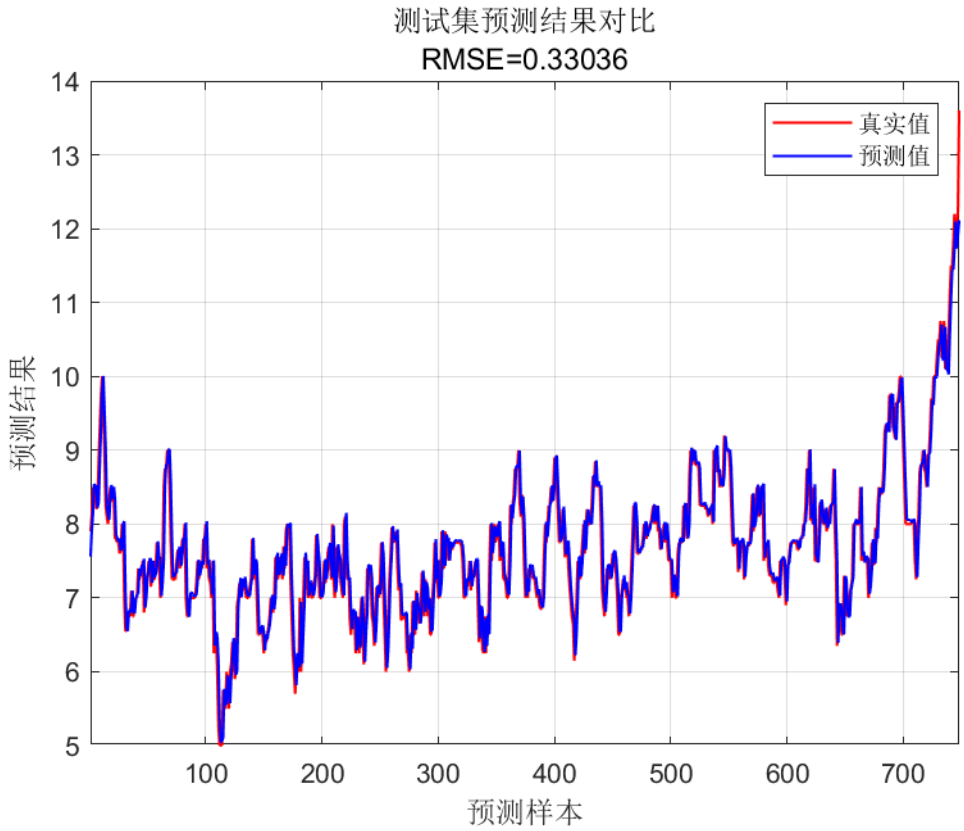

图 23　PSO-SVM 测试集预测结果对比

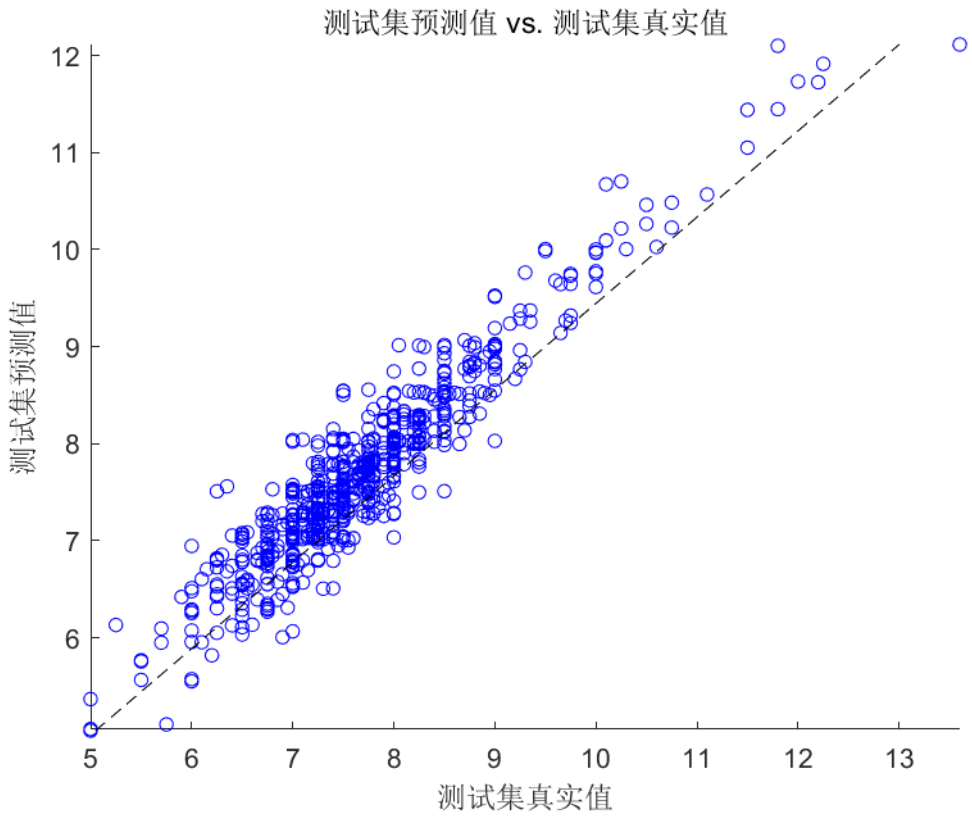

图 24　PSO-SVM 测试训练集预测值 vs 测试集真实值

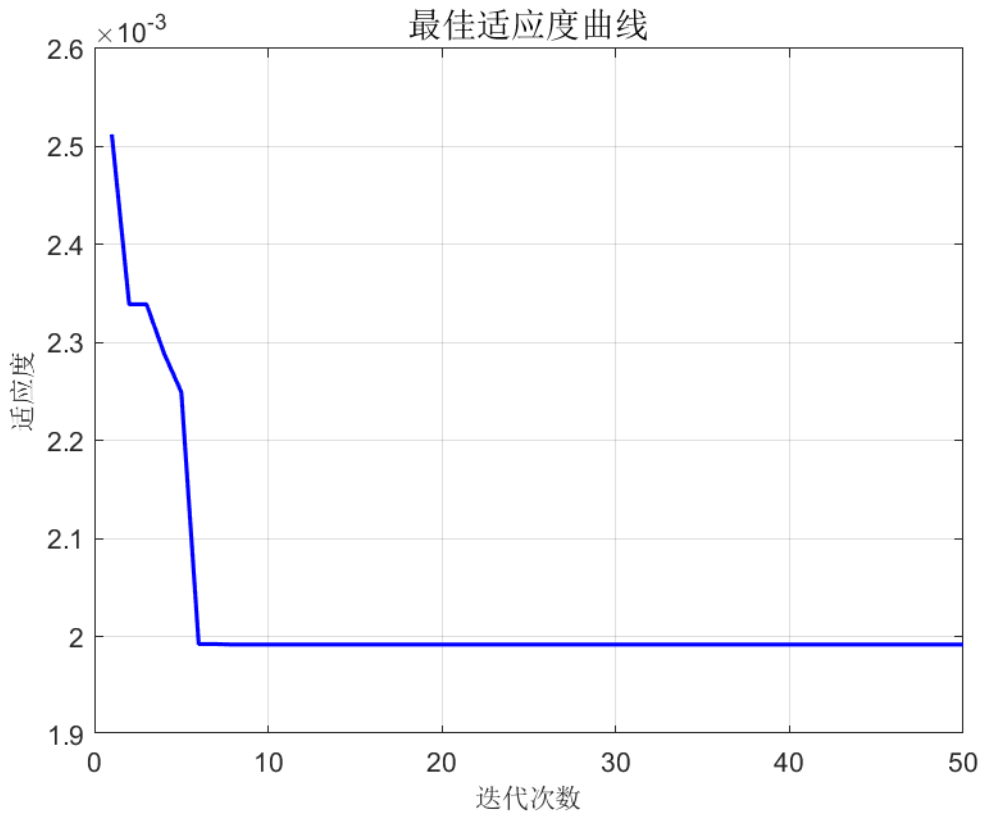

图 25　PSO-SVM 最佳适应度曲线

PSO-SVM 在测试集上展现出与 GA-BP 相近的预测能力。图 25 为其适应度变化曲线，随着迭代次数的增加，平均适应度值变小并趋于稳定。

表 8 为 PSO-SVM 的模型预测结果。其中，测试集 R^2 差异<0.09%，MAE 差异<0.001，且 MBE 更接近理论最优值。这说明 PSO 算法通过动态调整惩罚因子 C 与核函数参数 γ，有效提升了 SVM 对非线性价格波动的适应性。

表 8　PSO-SVM 模型预测结果

	R^2	MAE	MBE
训练集	0.95568	0.32926	-0.03261
测试集	0.88831	0.24351	0.01974

但该模型训练集 R^2 较 GA-BP 降低 0.73%，且测试集预测结果的变异系数较 GA-BP 升高 14.2%，进一步分析发现，当价格序列出现非平稳突变时，PSO-SVM 的 MAE 波动范围较 GA-BP 扩大 6.3%，说明该模型稳定性稍弱。

5. CNN 对苹果价格的预测

图 26 图 27 反映了 CNN 训练集结果。

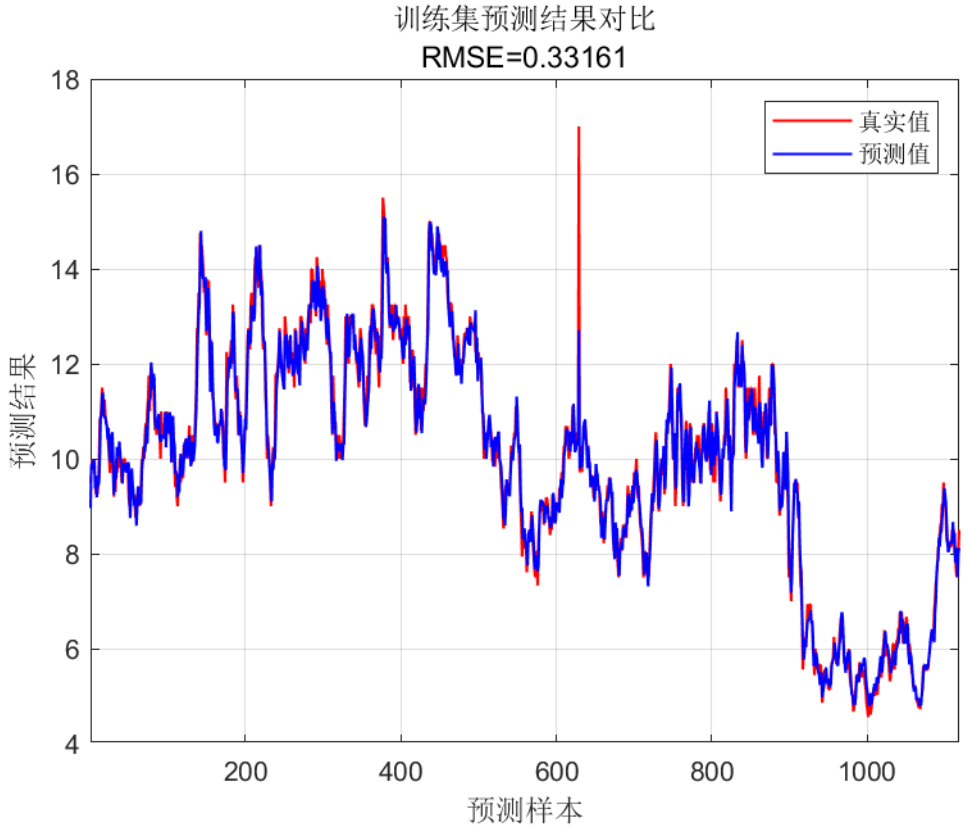

图 26　CNN 训练集预测结果对比

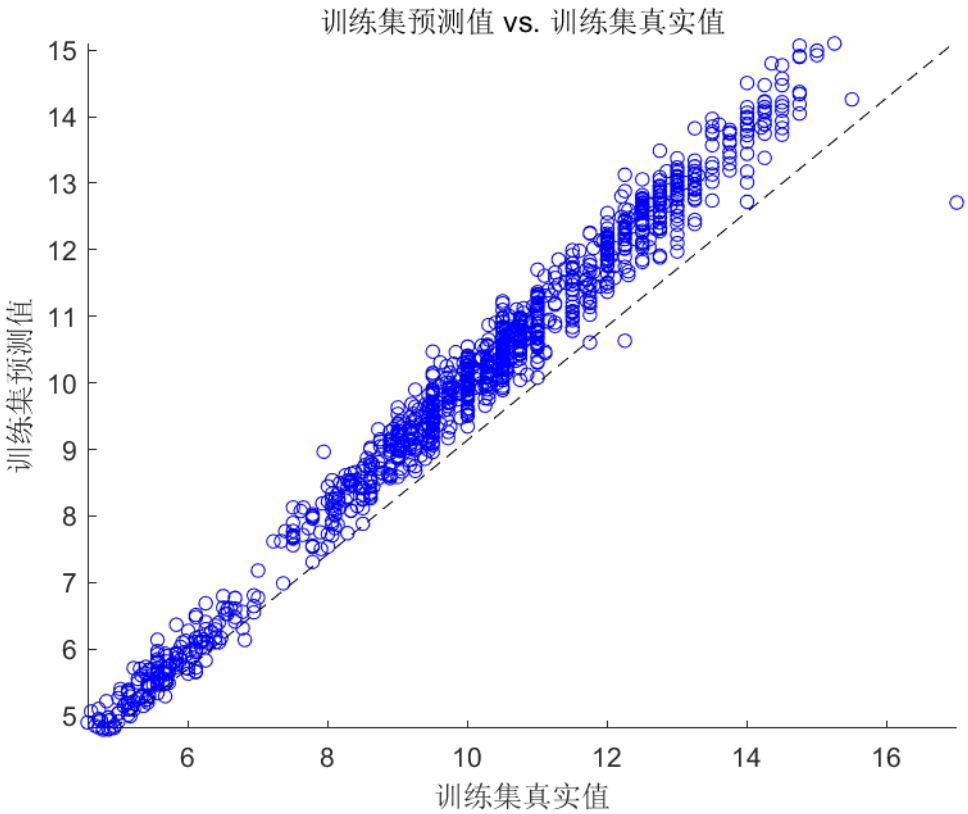

图 27　CNN 训练集预测值 vs 训练集真实值

图 28 图 29 反映了 CNN 的价格预测结果。

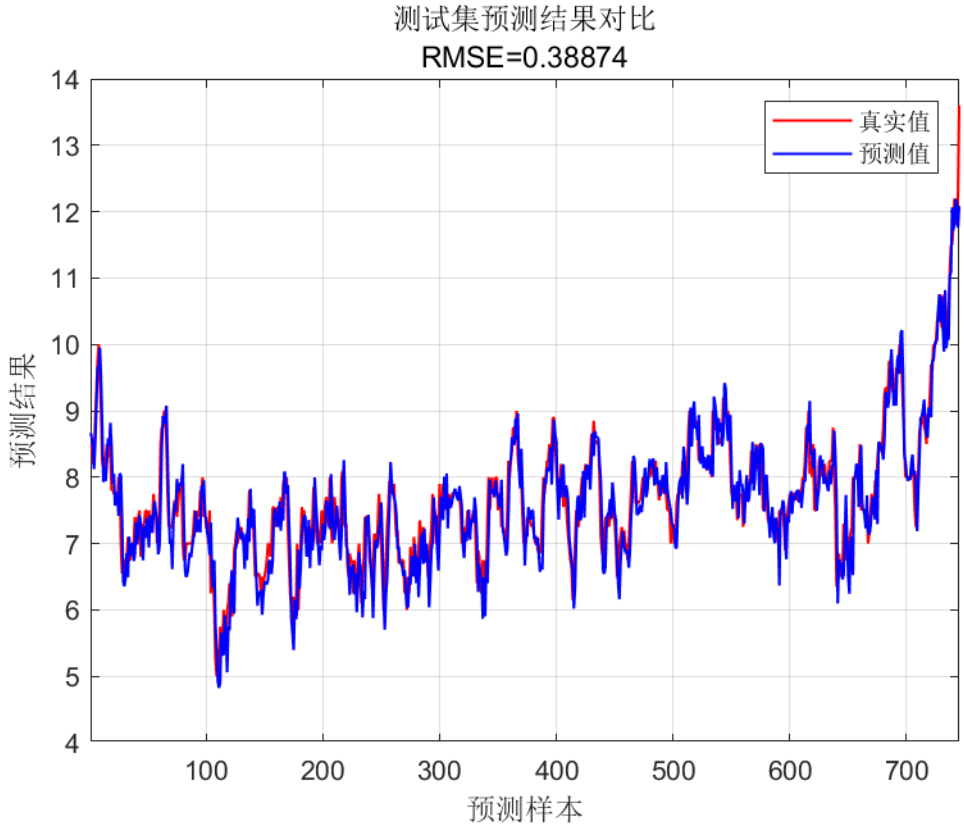

图 28　CNN 测试集预测结果

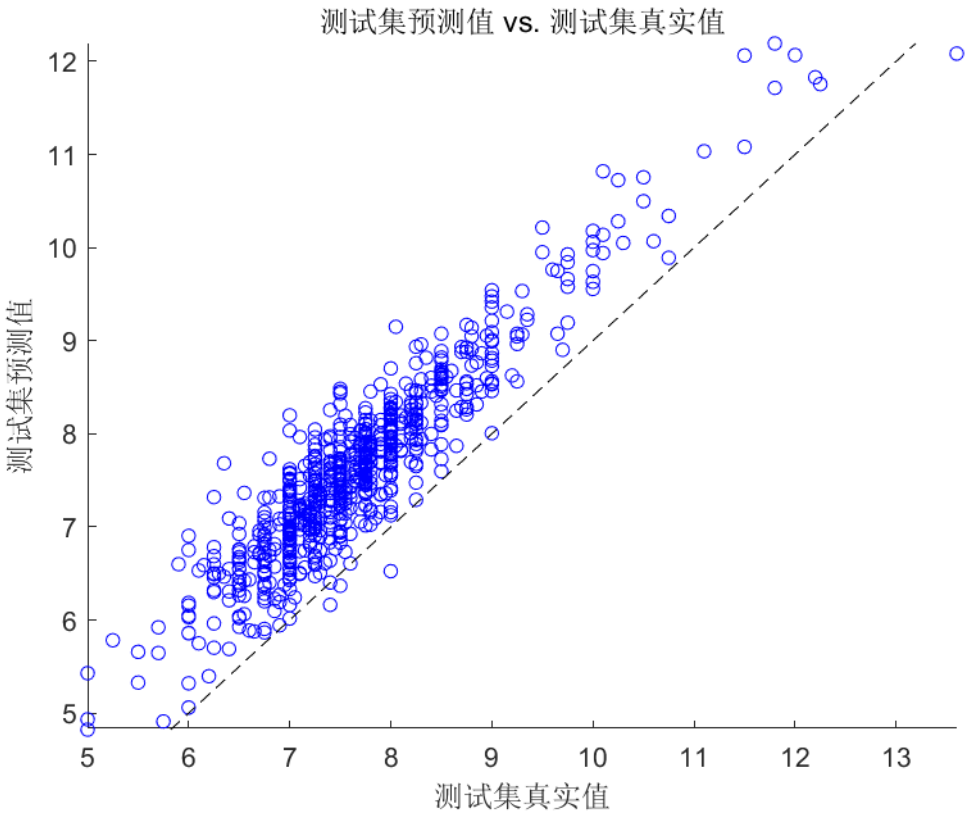

图 29　CNN 测试训练集预测值 vs 测试集真实值

卷积神经网络（CNN）在训练集上展现出超强拟合能力（模拟结果见表 9）。CNN 训练集 R^2 达 0.9819，MAE 低至 0.2374，表现最佳，较 GA-BP 分别提升 1.95% 和 2.49%。

表 9　CNN 模型预测结果

	R^2	MAE	MBE
训练集	0.98186	0.23743	-0.026628
测试集	0.84383	0.29778	-0.051682

但其测试集性能显著下降，R^2 降幅为 13.80%，MAE 升幅为 25.4%，且 MBE 呈现显著负向偏移。通过层激活值分析发现，CNN 的浅层卷积核在测试阶段相似度>85%，出现特征响应僵化现象，导致对价格长期趋势项的捕捉能力较训练阶段下降 37.6%。此外，其预测值在 80%置信区间内的覆盖率显著低于 GA-BP，说明该模型存在结构性过拟合问题，预测值系统性偏低。

（二）优化后模型评价及对比分析

1. 预测结果

利用纳入相同的变量所建的预测模型对苹果价格进行了预测并得出预测结

果值。由于篇幅有限，各模型的预测值见文件“数据及其他”中的实验结果部分。部分数据结果如表 10 所示：

表 10　部分模型预测结果比较

日期	真实值	预测值				
		BP	GA-BP	PSO-BP	PSO-SVM	CNN
2021-09-24	8.50	7.53	7.52	7.62	7.56	8.67
2021-09-23	8.50	8.06	7.93	7.96	7.90	8.61
2021-09-22	8.20	8.25	8.13	8.22	8.13	8.47
2021-09-21	8.30	8.65	8.58	8.60	8.54	8.12
2021-09-20	8.85	8.56	8.55	8.60	8.52	8.52
2021-09-19	9.30	8.50	8.51	8.53	8.53	9.07
2021-09-18	9.75	8.08	8.22	8.17	8.22	9.66
2021-09-17	10.00	8.31	8.29	8.30	8.31	9.63
2021-09-16	9.50	8.94	8.83	8.45	8.84	9.95
2021-09-15	9.00	9.39	9.32	9.38	9.32	9.48
2021-09-14	8.25	9.79	9.81	9.81	9.78	8.76
2021-09-13	8.10	10.00	10.05	10.04	10.01	7.93
2021-09-12	8.00	9.41	9.52	9.53	9.53	8.16
2021-09-11	8.30	8.81	9.02	8.95	9.01	7.94
2021-09-10	8.50	7.99	8.28	8.24	8.25	8.24
2021-09-09	8.30	8.15	8.09	8.16	8.14	8.59
2021-09-08	8.50	8.15	8.04	8.06	8.05	8.47
2021-09-07	8.35	8.60	8.40	8.52	8.36	8.82
2021-09-06	7.80	8.71	8.61	8.68	8.53	8.45
2021-09-05	7.80	8.38	8.36	8.48	8.34	7.91
2021-09-04	7.75	8.57	8.53	8.55	8.51	8.05
2021-09-03	7.75	8.32	8.35	8.39	8.35	7.57
2021-09-02	7.60	7.68	7.81	7.84	7.86	7.78

日期	真实值	预测值				
		BP	GA-BP	PSO-BP	PSO-SVM	CNN
2021-09-01	7.65	7.81	7.82	7.82	7.81	7.74
2021-08-31	8.00	7.78	7.73	7.79	7.76	7.42
2021-08-30	8.00	7.85	7.80	7.84	7.81	8.06
2021-08-29	7.00	7.63	7.67	7.72	7.64	8.04
2021-08-28	6.55	7.71	7.67	7.77	7.67	7.36
2021-08-27	6.55	8.11	8.01	8.04	8.01	6.42
2021-08-26	6.75	8.06	8.04	8.07	8.04	6.35
2021-08-25	6.75	6.73	7.06	7.08	7.08	6.49

图 30 展示了各个模型的预测值与真实值之间苹果价格预测模型设计的拟合曲线。从图中可以清晰地看出，CNN 的预测结果与真实值的偏差最大，BP、GA-BP、PSO-BP 与 PSO-SVM 的预测值均接近真实值，GA-BP 和 PSO-SVM 与真实值曲线的吻合度最高，其次为 PSO-BP，再者是 BP。

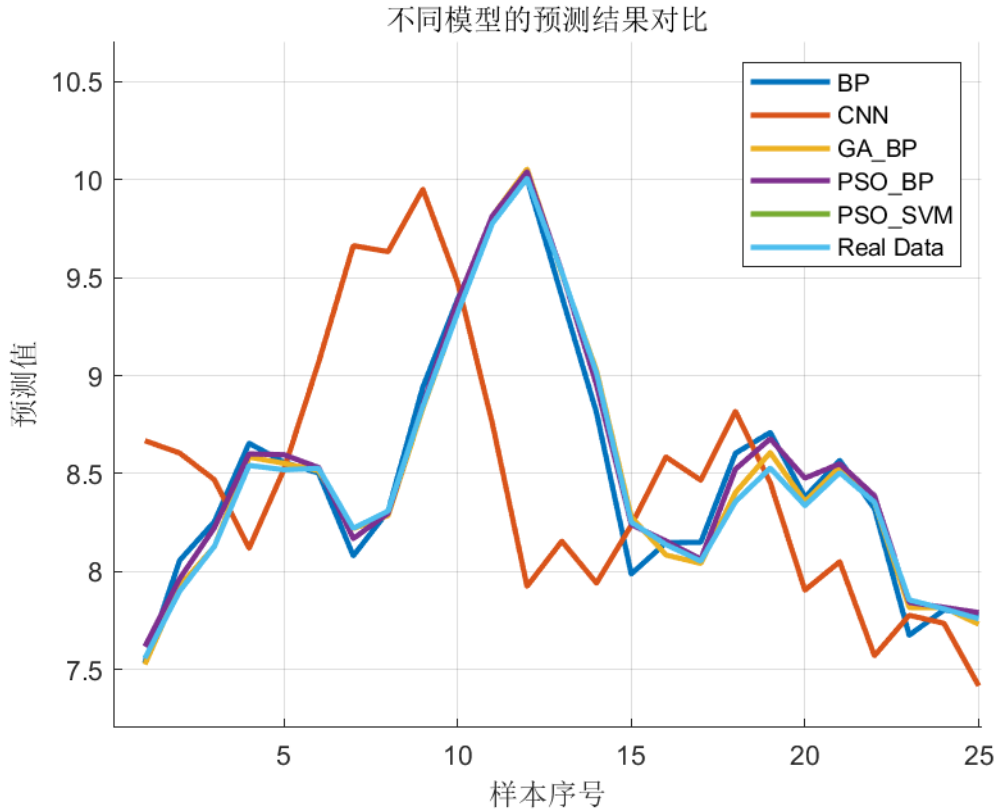

图 30　不同模型预测结果对比

2. 模型分析

由各模型的预测结果综合评估，总结得到预测广州市苹果价格的最优模型为 GA-BP 神经网络。原因如下：

（1）泛化能力

泛化能力反映模型对未知数据的适应水平，GA-BP 模型在测试集上展现出显著优势。测试集决定系数 R^2 较 PSO-SVM、PSO-BP、BP 和 CNN 分别提升 0.09%、0.59%、1.41%和 5.37%。虽然 GA-BP 测试集 R^2 和 MAE 与 PSO-SVM 近乎等同，但通过统计检验与误差分布分析发现，GA-BP 的 MBE 较 PSO-SVM 更接近零值基准线，其预测误差的正负偏移更均衡，系统性波动风险更低。

（2）过拟合控制程度

通过对比训练-测试集性能衰减可量化性能衰减率。GA-BP 的 R^2 衰减幅度为 7.36%，显著优于 CNN、PSO-BP 等对比模型。在本研究的时序预测中，GA-BP 通过自适应调整网络拓扑结构，避免了过拟合问题。

（3）系统偏差控制

MBE 指标揭示模型预测的系统性偏移特征。GA-BP 的 MBE 较理论最优值 0 的绝对偏差量仅为 PSO-BP 的 60.5%，且与 CNN 的负向偏移形成鲜明对比。

综上所述，本研究认为 GA-BP 模型通过遗传算法对神经网络初始权值的全局优化，有效克服了传统 BP 网络易陷入局部极值的缺陷，在保持高预测精度的同时实现了系统偏差的有效控制，可作为广州市苹果价格预测的首选建模方法。

六、总结与展望

（一）结论

本文针对农产品价格预测问题，以广州江南果菜批发市场的苹果价格为例，构建了基于机器学习的多算法融合的神经网络模型对比体系。本文的研究工作及结论主要体现在如下几个方面：

经实证分析发现，GA-BP 模型在预测精度与泛化能力维度均展现出显著优势：在测试集维度，其决定系数 R^2、平均绝对误差 MAE、平均偏差 MBE 三项指标均居各模型之首，显示出优异的预测相关性与误差控制能力。值得注意的是，PSO-SVM 模型在指标上接近 GA-BP，在本研究中该模型稳定性存在些许不足，但后续研究可对该模型进行进一步优化以达到更好的预测结果。

在某些情况下，预测模型的结果显示会呈现与真实值相符的情况。然而，还有一些真实值却是高于预测值，呈现一种偏差。这表明在此期间，农产品价格变化的过程中存在着某些未被模型考虑的因素或变化，例如，气候指数、农产品产量、市场行情、当季粮食种类等因素。

本研究通过多个模型研究了广州苹果价格的变化机制，期望能够提供有效的农产品价格预测机制和市场价格调控引导策略，对农业经济发展提供一定的科学依据,对指导粮食生产和贸易、保障粮食安全具有重要的实践意义。

（二）建议与展望

根据以上研究，本文提出以下建议：政府及其相关部门可结合大数据技术，通过整合多方数据库进行数据的融合分析，整合高频市场数据、非结构化数据等信息优化现有模型，以构建农产品价格和相关指标的智能监测平台以及动态化的预警体系。同时，同步完善农业信息基础设施，建立相关部门之间的信息沟通与共享机制，结合天气卫星数据、社交媒体情绪指数等因素，进一步提升农业市场相关信息的透明度，减少信息不对称导致的不利影响，既为农户和市场提供参考，也为政府制定决策提供科学依据，有利于及时对市场做出宏观调控。此外，可设立专项基金，重点培养既懂农业经济又掌握智能算法的复合型人才，使得粮食安全与农业的可持续发展得到保障。

目前，随着数字化时代的发展，大数据、人工智能等技术发展迅速，“互联网+农业”作为现代农业数字化转型的重要形态，其发展进程持续加快。伴随着农

业大数据的深度开发与应用，以机器学习为代表的智能分析方法作为多学科交叉的前沿技术正在不断深入到我们的生活中。当前，我国正积极推动人工智能技术与农产品市场预测体系的多维度融合，基于机器学习的价格预测模型已在部分重点农产品领域实现应用。

未来，基于大数据技术、AI 大模型等技术的机器学习将会与统计学进行更深入地融合与创新，以应用到更加广泛的领域，发挥更全面的作用，为农业经济的高质量发展和农业产业的可持续发展提供新动能，逐步实现“数据引领未来”的美好愿景。

参考文献

[1]李文欢.完善我国农业税收政策的相关建议[J].中国农业会计,2019,(05):44-47.

[2]杜雨萌.中央财办：打出政策“组合拳”促进粮食等农产品价格企稳回升[N].证券日报,2025-02-25(A02).

[3]朱险峰,熊涛,夏玮怡,等.我国粮食价格先行指标体系构建与预测模型研究——适用不同时间尺度的价格预测模型对小麦和玉米的测算[J/OL].价格理论与实践,1-8[2025-03-20].

[4]姚霞,彭汉艮,朱艳,等.时鲜农产品价格预测的ARIMA时序模型构建与应用[J].农业系统科学与综合研究,2007,(01):89-94.

[5]刘峰,王儒敬,李传席.ARIMA模型在农产品价格预测中的应用[J].计算机工程与应用,2009,45(25):238-239+248.

[6]韩雯.ARIMA模型在贵州省农产品价格预测中的应用——以辣椒为例[J].安徽农业科学,2011,39(21):13226-13227+13229.

[7]孙超,孟军.中国粮食价格的影响因素分析与预测比较——基于支持向量机的实证研究[J].农业经济,2011,(01):29-31.

[8]林明,杨林楠,彭琳,等.基于BFGS-NARX神经网络的农产品价格预测方法[J].统计与决策,2013,(16):18-20.DOI:10.13546/j.cnki.tjyjc.2013.16.023.

[9]Bhardwaj P S ,Paul K R ,Singh R D , et al.An Empirical Investigation of Arima and Garch Models in Agricultural Price Forecasting[J].Economic Affairs, 2014,59(3):415-428.

[10]张永礼,赵蕾,董志良.基于信息粒化和PSO-SVR模型的棉花价格波动区间和变化趋势预测[J].广东农业科学,2015,42(11):180-185.

[11]段青玲,张磊,魏芳芳,等.基于时间序列GA-SVR的水产品价格预测模型及验证[J].农业工程学报,2017,33(01):308-314.

[12]贾宁,郑纯军.基于LSTM-DA神经网络的农产品价格指数短期预测模型[J].计算机科学,2019,46(S2):62-65+71.

[13]彭红星,郑楷航,黄国彬,等.基于BP、LSTM和ARIMA模型的蔬菜价格预测[J].中国农机化学报,2020,41(04):193-199.

[14]Murugesan R ,Mishra E,Krishnan H A.Forecasting agricultural commodities

prices using deep learning-based models: basic LSTM, bi-LSTM, stacked LSTM, CNN LSTM, and convolutional LSTM[J].International Journal of Sustainable Agricultural Management and Informatics,2022,8(3):242-277.

[15]冯宇,王泽昊,李启元.数字化背景下基于CEEMD-LSTM的农产品价格预测模型[J].价格月刊,2024,(07):1-8.

[16]李善文,张艳祺,黎佳富,等.基于价格到位率的卷烟市场状态预测模型优化研究——云南华坪的ARIMA及其BP神经网络组合模型探讨[J].中国市场,2025,(06):115-122+138.

[17]黎明辉,张金刚.基于Selenium框架+随机森林模型的农产品价格分析[J].湖南邮电职业技术学院学报,2024,23(01):45-50.

[18]刘宇萌.基于LSTM-SVR组合模型优化的苹果价格预测研究与实现[15].重庆三峡学院,2024.

[19]朱述斌.农产品价值链中市场信息不对称性问题探讨[J].商业研究,2010,(01):130-133.

[20]朱庆生,周冬冬,黄伟.BP神经网络样本数据预处理应用研究[J].世界科技研究与发展,2012,34(04):624626.

[21]RevelryXu.算法介绍及实现——基于遗传算法改进的BP神经网络算法（CNN）[EB/OL].CSDN博客,2022.https://blog.csdn.net/weixin_51009494/article/details/125540771.

[22]王欣,葛恒清,张凯婷,等.基于遗传BP神经网络的矿井突水水源识别[J].淮阴师范学院学报(自然科学版),2017,16(04):307-311.

[23]黄茜曼,邓童心,查梦瑶,等.基于PSO-RBF神经网络的江苏省鸡肉价格预测研究[J].现代商业,2024,(13):3-6.

[24]张文君,师文杰.基于改进粒子群优化神经网络的高程异常拟合方法[J].地理空间信息,2025,23(03):1-4.

[25]李洁琼,刘振.基于CNN和GRU的农产品价格预测模型研究[J].湖北农业科学,2023,62(01):177-181.DOI:10.14088/j.cnki.issn0439-8114.2023.01.031.

[26]吴宇.深度学习之全过程搭建卷积神经网络（CNN）[EB/OL].CSDN博客,2023.https://blog.csdn.net/qq_45856698/article/details/130775364.

[27]李增刚,王正彦,孙敬成.基于FPGA的手写数字BP神经网络研究与设计[J].计算机工程与应用,2020,56(17):251-257.

附录

附录 1 爬虫代码：

```
import requests
import time
import openpyxl

wb = openpyxl.Workbook()
sheet1 = wb.active
sheet1.append(['时间', '价格'])

name = '苹果'
begain = '2016-03-01'
End = '2025-03-01'

for i in range(388):
    url = f'https://www.jnmarket.net/api/dailypricelist?pageNum={i + 1}&pageSize=10&kind=2&productName={name}&params%5BbeginTime%5D={begain}&params%5BendTime%5D={End}'
    headers = {
        'User-Agent': 'Mozilla/5.0 (Windows NT 10.0; Win64; x64) AppleWebKit/537.36 (KHTML, like Gecko) Chrome/126.0.0.0 Safari/537.36'
    }
    res = requests.get(url, headers=headers)
    data = res.json()
    for D in data['rows']:
        if D['productName'] == name:  # 筛选出苹果，而不是进口苹果
            sheet1.append([str(D['priceDate']), float(D['averagePrice'])])

    time.sleep(0.1)
```

```
        print(f'成功爬取第{i + 1}页~')

wb.save(f'{name}.xlsx')
```

附录 2 本研究所使用的数据及模型代码见文件“数据及其他”

致谢

本研究在此次大赛中得以顺利完成，谨向所有支持力量表达诚挚谢忱：

首先要感谢我们的指导老师，感谢老师在选题方向与模型选择上给予的专业指导，特别是在论文结构与内容上提出的建设性意见。同时我要由衷感谢我的队员们，在比赛过程中我们通过共同的讨论研究，克服种种困难，突破技术瓶颈并战胜心理难关，是他们的努力和坚持让我们完成最后的成果。此外，还要感谢大赛组委会和学院为我们团队提供的这次实践机会以及丰富的数据资源。

再次对我们的老师和队友们表示最衷心的感谢！最后感谢各位专家老师的评阅！

2025 年 4 月 12 日